



Relatório Mensal

Valor de Referência para o CIB



PoC

Florianópolis/SC

Equipe UFSC

abril, 2026

Índice

Prefácio	3
1 Introdução	4
1.1 Objetivo do Relatório	5
1.2 Síntese do avanço no período	5
1.2.1 Visão Geral do progresso técnico	6
1.2.2 Consolidação das principais frentes de trabalho	6
1.3 Principais entregas do trimestre	9
1.3.1 Lista sintética dos entregáveis concluídos	9
1.3.2 Destaque dos produtos estratégicos	10
1.4 Status geral do Projeto por Etapa	11
1.4.1 Etapa 0 - Planejamento e Governança	12
1.4.2 Etapa 1 - Observatório	12
1.4.3 Etapa 2 - Bases Territoriais	13
1.4.4 Etapa 3 - Modelagem e PVG	13
1.4.5 Etapa 4 - Internalização	13
1.4.6 Síntese do status geral	14
1.5 Principais Desafios e Riscos	14
1.5.1 Técnicos	15
1.5.2 Operacionais	15
1.5.3 Institucionais	16
1.6 Principais Resultados Estratégicos	17
1.6.1 Avanços metodológicos	17
1.6.2 Validação da PoC	17
1.6.3 Evolução da Infraestrutura	17
1.7 Próximos Passos	18
1.7.1 Ações prioritárias	18

1.7.2	Marcos previstos	18
2	Contextualização da PoC (Florianópolis)	19
2.1	Inserção da PoC no Projeto Nacional	20
2.1.1	Papel da PoC dentro do TED	20
2.1.2	Relação com macroetapas	20
2.2	Objetivos da PoC	20
2.2.1	Validação Metodológica	20
2.2.2	Teste de infraestrutura	20
2.2.3	Consolidação da fluxos	20
2.3	Escopo da PoC	20
2.3.1	Recorte territorial adotado	20
2.3.2	Base de dados utilizada	20
2.3.3	Variáveis consideradas	20
2.3.4	Atores institucionais envolvidos	20
2.4	Estratégia de execução da PoC	20
2.4.1	Abordagem incremental	20
2.4.2	Validações sucessivas	20
2.4.3	Integração entre etapas	20
2.5	Resultados esperados da PoC	20
2.5.1	Técnicos	20
2.5.2	Operacionais	20
2.5.3	Institucionais	20
I	Execução do Projeto por Etapas	21
3	ETAPA 0: Planejamento, Governança e Acompanhamento	22
3.1	Introdução da Etapa	23
3.2	Fluxo de Governança definido	23
3.2.1	Estrutura decisória	23
3.2.2	Fluxo de validação (UFSC -> RFB -> Comitê)	23
3.3	Atividades Desenvolvidas	23
3.3.1	Reuniões realizadas	23
3.3.2	Definição de instrumentos de gestão	23
3.3.3	Estruturação do Plano de Gerenciamento	23

3.4	Resultados Obtidos	23
3.4.1	Plano de Gerenciamento	23
3.4.2	Estrutura de Governança	23
3.4.3	Fluxos documentados	23
3.5	Desafios	23
3.6	Escalabilidade da Governança	23
4	ETAPA 1: Observatório do Mercado Imobiliário	24
5	Observatório do Mercado Imobiliário	25
5.1	Introdução da Etapa	25
5.2	Fluxo de dados estruturado	26
5.2.1	Fontes de dados	26
5.2.2	Ingestão	30
5.2.3	Tratamento	32
5.2.4	Armazenamento	41
5.3	Resultados Obtidos (V3)	42
5.3.1	Estrutura	42
5.3.2	Bases Consolidadas (V3)	43
5.3.3	Dicionário de dados (V3)	45
5.4	Análises Aprofundadas e Validação	46
5.4.1	1. Metodologia de Recuperação: Vias Curtas (Short Streets)	46
5.4.2	2. Análise Exploratória: Desempenho em Lotes e Terrenos	49
5.4.3	3. Validação de Acurácia (Benchmarking com Google Maps)	51
5.4.4	4. Recomendações e Próximos Passos	53
5.5	Desafios	54
5.5.1	Qualidade de dados	54
5.5.2	Validação Posicional e Integridade da Oferta são Processos Independentes	54
5.5.3	Padronização	55
5.5.4	Integração	55
5.6	Escalabilidade	56
5.6.1	Replicabilidade do modelo	56
5.6.2	Dependências externas	56

5.7	Conclusão	56
5.7.1	Resultado Final: Base Duplamente Validada	57
6	ETAPA 2: Bases Cartográficas Territoriais	59
6.1	Introdução	60
6.2	Fluxo de Estruturação Territorial	60
6.2.1	Entrada de dados cartográficos	60
6.2.2	Validação topológica	60
6.2.3	Padronização	60
6.3	Atividades desenvolvidas	60
6.3.1	Organização das bases	60
6.3.2	Validação geométrica	60
6.3.3	Integração com cadastro	60
6.4	Resultados	60
6.4.1	Base territorial estruturada	60
6.4.2	Consistência topológica	60
6.5	Desafios	60
6.6	Escalabilidade	60
7	ETAPA 3: Modelagem e Planta de Valores Genéricos (PVG)	61
7.1	Introdução	61
7.2	Fluxo de Modelagem	61
7.3	Limpeza dos dados	64
7.4	Definição de variáveis	65
7.4.1	Classificação de imóveis construídos (padrão construtivo)	66
7.4.2	Classificação espacial	69
7.5	Construção dos modelos	70
7.5.1	Modelo de imóveis edificadas	70
7.5.2	Modelo de Lotes	73
7.6	Atividades Desenvolvidas	74
7.6.1	Seleção de variáveis	74
7.6.2	Testes de modelos	75
7.7	Resultados	77
7.7.1	Superfície de valores de metro quadrado construído . .	77
7.7.2	Modelo preliminar	77
7.7.3	<i>Outputs</i> de valor	77

7.8	Desafios	77
7.8.1	Qualidade das variáveis	77
7.8.2	Aderência ao mercado	77
7.9	Escalabilidade	77
7.9.1	Replicação em outros municípios	77

II Blocos Transversais 78

8 Estudos Metodológicos 79

8.1	Fundamentos da Avaliação em Massa	79
8.1.1	Metodologia	80
8.1.2	Resultados	81
8.2	Definição de variáveis	86
8.3	Estratégias de modelagem	86
8.4	Conexão com Normas Técnicas	86
8.5	Aprendizados aplicados na PoC	86

9 Fluxo Integrado do Processo 87

9.1	Descrição do <i>Pipeline</i> Completo	87
9.2	Integração entre Etapas	87
9.3	Pontos de Controle e Validação	87
9.4	Interface com a RFB	87
9.5	Potencial de Automação	87

10 Visitas Técnicas e Intercâmbio de Conhecimento 88

10.1	Fortaleza	89
10.1.1	Objetivo da Missão	89
10.1.2	Instituições visitadas	89
10.1.3	Atividades realizadas	89
10.1.4	Principais aprendizados	89
10.1.5	Contribuições para o Projeto	89
10.2	Córdoba	89
10.2.1	Objetivo da Missão	89
10.2.2	Instituições e Interlocutores	89
10.2.3	Experiências observadas	89

10.2.4	Lições aprendidas	89
10.2.5	Aplicabilidade no Contexto Brasileiro	89
11	Infraestrutura Tecnológica (LABFSG)	90
11.1	Arquitetura de Infraestrutura	90
11.2	Servidores Disponíveis	91
11.2.1	produção	91
11.2.2	backup	91
11.2.3	dedicado ao projeto	92
11.3	Organização de Dados	92
11.3.1	Estrutura de diretórios	92
11.3.2	Versionamento	93
11.4	Banco de Dados	94
11.4.1	Estrutura PostGIS	94
11.4.2	Modelagem	95
11.5	Segurança e Governança dos Dados	95
11.5.1	controle de acesso	95
11.5.2	rastreabilidade	96
11.5.3	auditoria	96
12	Plataforma de Apresentação de Resultados	97
12.1	Objetivo da Plataforma	97
12.2	Funcionalidades	97
12.3	Dashboards desenvolvidos	97
12.4	Interface de Usuário	97
12.5	Potencial de uso pela RFB	97
12.6	Intergração com Sistemas (ex.: SINTER)	97
13	Entregáveis do período	98
13.1	Lista consolidada de entregáveis	98
13.2	Classificação por Etapa	98
13.3	Status dos Entregáveis	98
13.4	Evidências de entrega	98
13.5	Aderência aos critérios de qualidade	98

III Governança	99
14 Governança e Acompanhamento	100
14.1 Estrutura de Governança do Projeto	100
14.2 Reuniões realizadas	100
14.2.1 Comitê Técnico	100
14.2.2 Comitê Gestor	100
14.2.3 Reuniões operacionais	100
14.3 Processos de validação	100
14.4 Controle de Qualidade	100
14.5 Registro e rastreabilidade	100
15 Indicadores de Desempenho	101
15.1 Indicadores de Avanço Físico	101
15.2 Aderência ao cronograma	101
15.3 Qualidade dos dados	101
15.4 Qualidade dos modelos	101
15.5 Indicadores de governança	101
16 Próximos Passos	102
16.1 Continuidade da PoC	102
16.2 Ajustes metodológicos	102
16.3 Evolução da infraestrutura	102
16.4 Estratégia de escalonamento	102
16.5 Integração com Ambiente RFB	102
Referências	103
Apêndices	104
A Diagramas de Fluxo	104
B Arquitetura Tecnológica	105
C Relatórios Técnicos Detalhados	106

D Scripts e documentações	107
E Evidências de entregas	108

Prefácio

This is a Quarto book.

To learn more about Quarto books visit <https://quarto.org/docs/books>.

[1] 2

1 Introdução

O presente relatório técnico tem por finalidade apresentar, de forma estruturada e detalhada, o avanço das atividades desenvolvidas no âmbito do Projeto TED firmado entre a Receita Federal do Brasil (RFB) e a Universidade Federal de Santa Catarina (UFSC), voltado à construção, validação e institucionalização de uma metodologia nacional para determinação de Valores de Referência de imóveis urbanos, em consonância com as diretrizes estabelecidas pela Lei Complementar nº 214/2025 e com as demandas do novo sistema tributário brasileiro.

O período contemplado neste relatório corresponde ao ciclo trimestral de acompanhamento do projeto (período de XXX aXXX), no qual foram desenvolvidas atividades estratégicas relacionadas à implementação da Prova de Conceito (POC) no município de Florianópolis. Essa POC tem papel central no projeto, pois constitui o ambiente de experimentação, validação e consolidação dos processos metodológicos, tecnológicos e operacionais que darão suporte à futura aplicação em escala nacional.

Neste contexto, o relatório abrange de forma integrada as atividades realizadas nas diferentes etapas do projeto, desde a estruturação da governança e organização dos dados até o desenvolvimento de modelos de avaliação em massa e a preparação para sua internalização. São apresentados os fluxos estabelecidos, os resultados obtidos, os estudos realizados para embasamento metodológico, as iniciativas de intercâmbio técnico, bem como a infraestrutura tecnológica implantada para suporte às atividades.

Adicionalmente, o documento evidencia os principais entregáveis produzidos no período, os desafios enfrentados ao longo da execução, os avanços alcançados em termos de consolidação metodológica e os aspectos relacionados à escalabilidade da solução proposta. A abordagem adotada busca garantir não apenas o

registro das atividades realizadas, mas também a rastreabilidade dos processos, a transparência das decisões técnicas e a aderência aos critérios de qualidade e governança definidos no projeto.

Por fim, o relatório se insere no contexto de acompanhamento sistemático das ações do TED, contribuindo para o alinhamento entre as equipes técnicas da UFSC e da RFB, e subsidiando as instâncias de validação e tomada de decisão, com vistas à consolidação de uma solução robusta, auditável e replicável para o território nacional.

1.1 Objetivo do Relatório

Este relatório tem como objetivo consolidar, de forma sistematizada, as evidências técnicas e operacionais das atividades desenvolvidas no período, no contexto da implementação da Prova de Conceito (POC) em Florianópolis. O documento organiza e apresenta os principais resultados alcançados, os fluxos estruturados, os produtos gerados e os desafios identificados ao longo da execução das diferentes etapas do projeto.

Adicionalmente, busca-se evidenciar o grau de maturidade das soluções desenvolvidas, especialmente no que se refere à estruturação dos dados, à modelagem de avaliação em massa e à preparação para a internalização dos processos. O relatório também tem a função de apoiar o acompanhamento contínuo do projeto, oferecendo subsídios técnicos para análise, validação e encaminhamento das próximas fases, em alinhamento com as diretrizes estabelecidas pela Receita Federal do Brasil.

1.2 Síntese do avanço no período

A síntese a seguir apresenta uma visão consolidada do avanço das atividades no período, estruturada a partir de dois eixos complementares: (i) a análise do progresso técnico alcançado nas principais frentes do projeto e (ii) a consolidação das atividades desenvolvidas, evidenciando a integração entre dados,

modelagem, infraestrutura e governança. Essa abordagem permite não apenas compreender o estágio atual da Prova de Conceito (POC) em Florianópolis, mas também identificar os elementos já estruturados e aqueles em processo de amadurecimento, com foco na construção de uma arquitetura de dados robusta, na consistência dos processos e na preparação para escalabilidade da solução.

1.2.1 Visão Geral do progresso técnico

No período analisado, observou-se avanço consistente na estruturação da Prova de Conceito (POC) de Florianópolis, com evolução integrada nas frentes de dados, modelagem, infraestrutura e governança. Esse avanço reflete a consolidação inicial do fluxo estruturado do processo, articulando de forma progressiva as etapas de organização das bases de dados, tratamento das informações e desenvolvimento preliminar dos modelos de avaliação em massa.

Destaca-se, nesse contexto, a evolução na construção da arquitetura de dados do projeto, com a integração de diferentes fontes e a organização de um ambiente estruturado que possibilita o processamento e a análise das informações de forma consistente e rastreável. Paralelamente, houve avanço significativo na organização das bases cartográficas territoriais e na definição das variáveis geoespaciais e cadastrais que subsidiam a modelagem.

No campo da modelagem, foram realizados testes iniciais com geração de resultados preliminares, os quais permitem não apenas avaliar o desempenho dos modelos, mas também validar, de forma incremental, a abordagem metodológica adotada. Esses resultados constituem uma base importante para o refinamento das etapas subsequentes e para a consolidação do processo em direção à escalabilidade.

1.2.2 Consolidação das principais frentes de trabalho

As principais frentes de trabalho consolidadas no trimestre refletem o avanço integrado das dimensões estruturantes do projeto, articulando dados, território,

modelagem, infraestrutura e governança. A seguir, detalham-se essas frentes com base nas atividades desenvolvidas e nos resultados obtidos:

- **Estruturação da arquitetura de dados e integração de bases heterogêneas:** Esta frente concentrou esforços na organização de um ambiente estruturado para armazenamento, tratamento e integração de dados provenientes de diferentes fontes, com distintas características e níveis de qualidade. Foram realizadas atividades de padronização, limpeza, compatibilização e consolidação das bases, permitindo a construção de uma arquitetura de dados capaz de suportar análises consistentes e reproduzíveis. Esse processo foi fundamental para viabilizar a integração entre dados cadastrais, territoriais e de mercado, estabelecendo a base para as etapas subsequentes do projeto.
- **Organização e validação das bases territoriais:** As atividades desta frente envolveram a estruturação das bases cartográficas utilizadas na POC, com foco na consistência geométrica, topológica e na aderência ao sistema de referência adotado. Foram realizados procedimentos de validação para garantir a integridade espacial dos dados, incluindo verificação de sobreposições, lacunas e inconsistências geométricas. A organização dessas bases é essencial para assegurar a qualidade das análises espaciais e a correta associação entre imóveis, atributos e valores.
- **Definição e tratamento de variáveis geoespaciais e cadastrais:** Nesta frente, foram identificadas, estruturadas e tratadas as variáveis que compõem os modelos de avaliação em massa, considerando aspectos locais, físicos e funcionais dos imóveis. O processo incluiu a seleção de variáveis relevantes, a padronização de atributos, o tratamento de inconsistências e a geração de novas variáveis derivadas, especialmente de natureza geoespacial. Essa etapa é determinante para a qualidade dos modelos, uma vez que influencia diretamente sua capacidade explicativa e preditiva.
- **Desenvolvimento inicial dos modelos de avaliação em massa:** Foram conduzidos testes iniciais de modelagem com base nas variáveis estruturadas, visando a construção de modelos capazes de estimar valores de referência de forma sistemática. As atividades incluíram a definição

de abordagens metodológicas, a aplicação de técnicas estatísticas e computacionais e a análise dos resultados obtidos. Os modelos desenvolvidos nesta fase possuem caráter preliminar, sendo utilizados para validação da metodologia e identificação de ajustes necessários para aprimoramento.

- **Implementação da infraestrutura tecnológica no laboratório:** Paralelamente às atividades técnicas, foi implantada a infraestrutura computacional necessária para suporte ao projeto, incluindo servidores dedicados, ambiente de armazenamento e organização de dados, bem como ferramentas para processamento e análise. Essa infraestrutura foi estruturada de forma a garantir desempenho, segurança, controle de acesso e rastreabilidade das informações, constituindo um elemento fundamental para a execução das atividades e para a escalabilidade futura.
- **Estruturação dos fluxos de governança e validação técnica:** Foi estabelecido um fluxo estruturado de governança, contemplando a organização das instâncias de decisão, os processos de validação técnica e os mecanismos de acompanhamento das atividades. Esse fluxo assegura que os produtos desenvolvidos sejam submetidos à análise e validação pelas instâncias competentes, promovendo alinhamento institucional, controle de qualidade e formalização das decisões ao longo do projeto.
- **Realização de intercâmbios técnicos para fortalecimento metodológico:** Foram realizadas atividades de intercâmbio técnico com instituições e especialistas, com o objetivo de incorporar boas práticas, referências metodológicas e experiências consolidadas na área de cadastro territorial e avaliação imobiliária. Essas iniciativas contribuíram para o aprimoramento da abordagem adotada no projeto, ampliando a base de conhecimento e fortalecendo a consistência técnica das soluções desenvolvidas.

1.3 Principais entregas do trimestre

1.3.1 Lista sintética dos entregáveis concluídos

- As entregas realizadas no período refletem o avanço estruturado das atividades do projeto, evidenciando a consolidação progressiva dos componentes necessários à implementação da Prova de Conceito (POC). A seguir, detalham-se os principais entregáveis, com a respectiva contextualização técnica:
- Estrutura inicial da arquitetura de dados com bases integradas: foi consolidada uma primeira versão da arquitetura de dados do projeto, contemplando a integração de diferentes bases provenientes de fontes diversas. Essa estrutura permite o armazenamento organizado, o tratamento padronizado e a recuperação eficiente das informações, constituindo o núcleo operacional para suporte às análises e à modelagem.
- Organização e padronização das bases cartográficas da POC: as bases territoriais foram organizadas e submetidas a processos de padronização, garantindo consistência geométrica, compatibilidade de sistemas de referência e adequação para uso em análises espaciais. Esse processo assegura a integridade da base territorial e sua integração com os demais componentes do projeto.
- Conjunto inicial de variáveis geoespaciais estruturadas: foi desenvolvido um conjunto inicial de variáveis derivadas e estruturadas, considerando atributos locacionais, físicos e cadastrais dos imóveis. Essas variáveis foram tratadas e organizadas de modo a subsidiar os modelos de avaliação em massa, representando os principais fatores que influenciam a formação de valor.
- Modelos preliminares de avaliação em massa: foram implementados modelos iniciais com base nas variáveis estruturadas, permitindo a geração de estimativas preliminares de valor. Esses modelos possuem caráter exploratório e são fundamentais para validação da abordagem metodológica, bem como para identificação de ajustes necessários nas etapas subsequentes.

- Scripts de processamento e tratamento de dados: foram desenvolvidos scripts para automatização dos processos de ingestão, tratamento, transformação e análise de dados. Esses scripts garantem padronização, reprodutibilidade e eficiência operacional, além de constituírem base essencial para futura escalabilidade.
- Estrutura de armazenamento e versionamento implantada: foi implementada uma estrutura organizada de armazenamento de dados e versionamento de arquivos, assegurando controle sobre as diferentes versões de bases, scripts e produtos gerados. Essa estrutura é fundamental para garantir rastreabilidade, auditoria e governança da informação.
- Relatórios técnicos intermediários de acompanhamento: foram elaborados relatórios técnicos parciais com o objetivo de documentar o avanço das atividades, registrar decisões metodológicas e consolidar os resultados obtidos em cada etapa. Esses documentos contribuem para a transparência e o acompanhamento contínuo do projeto.
- Estrutura inicial de visualização de resultados (dashboards): foi desenvolvida uma estrutura inicial de visualização dos resultados, por meio de dashboards que permitem a análise exploratória das informações e dos outputs dos modelos. Essa ferramenta representa um primeiro passo na construção de interfaces voltadas à interpretação e utilização dos resultados

1.3.2 Destaque dos produtos estratégicos

Dentre as entregas realizadas, destacam-se alguns produtos com maior relevância estratégica para o projeto, por sua contribuição direta à consolidação metodológica, à validação da POC e à preparação para escalabilidade:

- Consolidação da arquitetura de dados estruturada: a estruturação da arquitetura de dados representa um dos pilares do projeto, viabilizando a integração de informações e garantindo a base necessária para análises consistentes e replicáveis em outros contextos.

- Primeira versão funcional do modelo de avaliação em massa: a implementação de um modelo funcional, ainda que preliminar, constitui um marco importante, pois demonstra a viabilidade técnica da abordagem adotada e permite avaliar o comportamento das variáveis e dos resultados.
- Definição do fluxo integrado do processo (pipeline metodológico): foi estabelecido um fluxo estruturado que conecta todas as etapas do projeto — desde a organização dos dados até a geração dos valores — garantindo coerência, rastreabilidade e clareza metodológica.
- Implantação da infraestrutura tecnológica dedicada ao projeto: a disponibilização de ambiente computacional estruturado assegura capacidade de processamento, armazenamento e segurança das informações, sendo condição essencial para a execução e continuidade das atividades.
- Estruturação dos mecanismos de rastreabilidade e auditabilidade: foram implementados mecanismos que permitem o acompanhamento detalhado das transformações realizadas nos dados e nos modelos, garantindo transparência, controle e aderência aos requisitos institucionais da RFB.

1.4 Status geral do Projeto por Etapa

A avaliação do status do projeto no período foi realizada com base no avanço físico das atividades, considerando a execução das etapas previstas no plano de trabalho, bem como a evolução dos diferentes lotes de produção associados à Prova de Conceito (POC) de Florianópolis e à estratégia de expansão territorial.

Para fins de acompanhamento, foi estruturado um cronograma físico de execução, complementado por painéis de monitoramento (dashboards), que permitem visualizar quantitativamente o progresso das atividades, incluindo volume de dados processados, número de registros estruturados, variáveis geradas e modelos testados. Esses instrumentos possibilitam uma leitura integrada do avanço do projeto, tanto sob a perspectiva técnica quanto operacional.

Adicionalmente, foi definida uma estratégia de execução baseada em lotes de trabalho, permitindo organizar o desenvolvimento de forma escalonada e controlada. Essa estratégia contempla:

- POC Florianópolis – ambiente de validação metodológica
- Lote 1 – primeira expansão controlada
- Lote 2, Lote 3, Lote 4 e Lote 5 – escalonamento progressivo por regiões
- Estruturação por capitais, regiões e sub-regiões administrativas, visando replicabilidade nacional

Essa organização permite testar, ajustar e consolidar os processos em diferentes contextos territoriais, garantindo robustez e aderência da metodologia antes da ampliação em escala nacional.

A seguir, apresenta-se o status consolidado por etapa.

1.4.1 Etapa 0 - Planejamento e Governança

As atividades relacionadas à estruturação da governança do projeto foram concluídas e validadas, incluindo a definição dos fluxos de decisão, organização das instâncias técnicas e estabelecimento dos mecanismos de acompanhamento e controle. Essa etapa garantiu a base institucional necessária para o desenvolvimento das demais fases.

1.4.2 Etapa 1 - Observatório

A Etapa 1 apresenta avanço significativo, com a consolidação da arquitetura de dados no âmbito da POC Florianópolis e início de expansão para outros lotes. Destaca-se:

- Estruturação do ambiente de dados integrado
- Processamento e organização das bases da POC
- Avanço inicial do Lote 1 do Observatório, com replicação da lógica de estruturação

Os dashboards indicam crescimento consistente no volume de dados tratados e integrados, evidenciando maturidade progressiva da arquitetura de dados.

1.4.3 Etapa 2 - Bases Territoriais

A Etapa 2 encontra-se em desenvolvimento, com avanço relevante tanto na POC quanto nos lotes iniciais de expansão.

Destaca-se:

- Organização e validação das bases cartográficas da POC
- Avanço do Lote 1 da cartografia, com estruturação inicial das bases territoriais
- Início do Lote 2 da cartografia, com preparação e organização dos dados

Os indicadores demonstram evolução no quantitativo de feições territoriais estruturadas, bem como melhoria na consistência topológica das bases.

1.4.4 Etapa 3 - Modelagem e PVG

A Etapa 3 apresenta avanço inicial, concentrado na POC Florianópolis, com desenvolvimento de modelos preliminares.

Destaca-se: - Aplicação inicial das variáveis estruturadas - Execução de testes de modelagem - Geração de resultados preliminares

Os dashboards evidenciam evolução no número de modelos testados e na capacidade de processamento das variáveis, indicando progresso consistente, ainda em fase de validação metodológica.

1.4.5 Etapa 4 - Internalização

A Etapa 4 ainda não foi iniciada formalmente, encontrando-se em fase de preparação conceitual e técnica.

As atividades em andamento nas etapas anteriores já incorporam elementos fundamentais para a internalização futura, como: - padronização de processos - estruturação da arquitetura de dados - definição de fluxos replicáveis

Essa preparação é essencial para garantir que a transição para o ambiente institucional da RFB ocorra de forma estruturada e segura.

1.4.6 Síntese do status geral

A análise integrada do cronograma físico e dos indicadores operacionais demonstra que o projeto se encontra em estágio consistente de desenvolvimento, com: - Consolidação da POC Florianópolis como ambiente de validação - Avanço progressivo dos primeiros lotes de expansão - Estruturação das bases necessárias para escalabilidade - Evolução contínua da arquitetura de dados, cartografia e modelagem

A estratégia baseada em lotes tem se mostrado adequada, permitindo controle do processo, validação incremental e preparação estruturada para expansão em nível nacional.

1.5 Principais Desafios e Riscos

A execução da Prova de Conceito (POC) no âmbito do Projeto TED RFB/UFSC envolve um conjunto de atividades interdependentes, que abrangem desde a estruturação de bases de dados até o desenvolvimento de modelos de avaliação e a preparação para sua internalização em ambiente institucional. Nesse contexto, a identificação e análise dos desafios e riscos associados ao processo são fundamentais para garantir o adequado acompanhamento do projeto, permitindo antecipar limitações, orientar ajustes metodológicos e apoiar a tomada de decisão.

Os desafios observados no período podem ser organizados em três dimensões complementares — técnica, operacional e institucional —, refletindo tanto a complexidade inerente ao desenvolvimento da metodologia quanto as exigências de integração, governança e escalabilidade impostas pelo projeto. A seguir, são detalhados os principais aspectos identificados em cada uma dessas dimensões.

1.5.1 Técnicos

Os desafios técnicos observados no período estão diretamente associados à natureza estrutural do projeto, que depende da integração de múltiplas bases de dados heterogêneas, com diferentes níveis de qualidade, granularidade e padronização. A consolidação do Data Lake evidenciou a necessidade de tratamento intensivo de dados, incluindo limpeza, harmonização e definição de padrões mínimos para viabilizar análises consistentes.

Outro ponto crítico refere-se à definição e construção das variáveis explicativas utilizadas nos modelos de avaliação em massa. A seleção adequada dessas variáveis exige não apenas disponibilidade de dados, mas também consistência espacial, aderência ao comportamento do mercado imobiliário e capacidade de generalização para diferentes contextos territoriais.

Adicionalmente, a etapa de modelagem apresentou desafios relacionados à calibração dos modelos, especialmente no equilíbrio entre precisão estatística e interpretabilidade, aspecto essencial para a futura adoção institucional pela RFB. A reprodutibilidade dos resultados e a rastreabilidade dos processos também se configuram como requisitos técnicos críticos, exigindo controle rigoroso de versões, scripts e bases utilizadas.

Principais desafios e riscos técnicos: - Heterogeneidade e baixa padronização das bases de dados - Inconsistências e lacunas nos dados utilizados - Complexidade na definição e validação de variáveis - Dificuldade de calibração dos modelos em contextos reais - Necessidade de garantir reprodutibilidade e rastreabilidade - Dependência da qualidade dos dados para robustez dos resultados

1.5.2 Operacionais

No âmbito operacional, os principais desafios estão relacionados à execução coordenada de múltiplas frentes de trabalho, que envolvem processamento intensivo de dados, desenvolvimento técnico e validação contínua. O volume de informações manipuladas no projeto exige infraestrutura adequada, organização rigorosa dos fluxos e definição clara de responsabilidades.

A necessidade de integração entre diferentes etapas — desde a coleta de dados até a geração de resultados — impõe uma dependência direta da maturidade dos processos estabelecidos. Qualquer fragilidade em uma etapa impacta as subsequentes, exigindo retrabalho e ajustes constantes.

Outro aspecto relevante é a necessidade de formalização e padronização dos fluxos operacionais, garantindo que os processos desenvolvidos na POC possam ser replicados em outros contextos. Isso inclui documentação técnica, organização dos scripts e definição de rotinas automatizadas.

Além disso, a dependência de dados externos e de interlocução com diferentes instituições pode impactar prazos e a continuidade das atividades, configurando um risco operacional relevante.

1.5.3 Institucionais

Os desafios institucionais estão associados, principalmente, à necessidade de alinhamento entre os diferentes atores envolvidos no projeto, especialmente no que se refere à validação técnica, tomada de decisão e futura internalização da metodologia pela Receita Federal do Brasil.

A governança do projeto exige um fluxo estruturado de validação, no qual os produtos desenvolvidos pela UFSC devem ser analisados tecnicamente pela RFB e, posteriormente, deliberados em instâncias formais. Esse processo, embora essencial para garantir qualidade e legitimidade, pode introduzir tempos adicionais no ciclo de desenvolvimento.

Outro ponto crítico refere-se à preparação para a internalização dos resultados, que envolve não apenas aspectos técnicos, mas também adequação a sistemas institucionais, conformidade com normas internas e aderência a requisitos legais e operacionais.

Adicionalmente, a necessidade de consolidação de uma metodologia nacional implica garantir que os resultados obtidos na POC sejam compreensíveis, auditáveis e aceitos institucionalmente, o que exige clareza metodológica, transparência e documentação rigorosa.

Principais desafios e riscos institucionais: - Necessidade de alinhamento contínuo entre UFSC e RFB - Dependência de processos formais de validação e decisão - Risco de aumento de prazos devido à governança - Desafios na internalização em ambiente institucional - Necessidade de aderência a normas e requisitos legais - Exigência de transparência e auditabilidade metodológica

1.6 Principais Resultados Estratégicos

1.6.1 Avanços metodológicos

- Estruturação de um fluxo integrado para avaliação em massa
- Definição de abordagem baseada em dados e variáveis geoespaciais
- Desenvolvimento de modelos replicáveis em escala nacional

1.6.2 Validação da PoC

- Comprovação da viabilidade técnica da abordagem proposta
- Geração de resultados preliminares consistentes
- Integração entre dados, modelos e visualização

1.6.3 Evolução da Infraestrutura

- Implantação de ambiente computacional dedicado ao projeto
- Estruturação de servidores e armazenamento de dados
- Implementação de práticas de versionamento e rastreabilidade

1.7 Próximos Passos

1.7.1 Ações prioritárias

- Refinamento dos modelos de avaliação em massa
- Aprimoramento da qualidade e consistência dos dados
- Consolidação dos fluxos automatizados de processamento
- Evolução da plataforma de visualização de resultados
- Estruturação dos mecanismos de internalização

1.7.2 Marcos previstos

- Validação técnica dos modelos preliminares junto à RFB
- Consolidação da base territorial validada
- Entrega de versão aprimorada do Data Lake
- Estruturação do ambiente de integração com sistemas institucionais
- Início da Etapa 4 (Internalização e Operação)

2 Contextualização da PoC (Florianópolis)

2.1 Inserção da PoC no Projeto Nacional

2.1.1 Papel da PoC dentro do TED

2.1.2 Relação com macroetapas

2.2 Objetivos da PoC

2.2.1 Validação Metodológica

2.2.2 Teste de infraestrutura

2.2.3 Consolidação da fluxos

2.3 Escopo da PoC

2.3.1 Recorte territorial adotado

2.3.2 Base de dados utilizada

2.3.3 Variáveis consideradas

2.3.4 Atores institucionais envolvidos

2.4 Estratégia de execução da PoC

2.4.1 Abordagem incremental

2.4.2 Validações sucessivas



Parte I

Execução do Projeto por Etapas

3 ETAPA 0: Planejamento, Governança e Acompanhamento

3.1 Introdução da Etapa

3.2 Fluxo de Governança definido

3.2.1 Estrutura decisória

3.2.2 Fluxo de validação (UFSC → RFB → Comitê)

3.3 Atividades Desenvolvidas

3.3.1 Reuniões realizadas

3.3.2 Definição de instrumentos de gestão

3.3.3 Estruturação do Plano de Gerenciamento

3.4 Resultados Obtidos

3.4.1 Plano de Gerenciamento

3.4.2 Estrutura de Governança

3.4.3 Fluxos documentados

3.5 Desafios

3.6 Escalabilidade da Governança

4 ETAPA 1: Observatório do Mercado Imobiliário

Prova de Conceito - Florianópolis/SC

5 Observatório do Mercado Imobiliário

5.1 Introdução da Etapa

O presente relatório detalha a metodologia e os resultados da Prova de Conceito (PoC) do Observatório do Mercado Imobiliário (OMI), realizada em Florianópolis/SC. O monitoramento do mercado por meio de dados de portais web é uma prática consolidada na América Latina como instrumento de apoio à avaliação em massa e à política fiscal. Neste contexto, o objetivo principal deste projeto é construir uma base de dados limpa e confiável para apoiar a Receita Federal do Brasil (RFB) no cálculo do Valor de Referência do Cadastro Imobiliário Brasileiro (CIB), superando a dependência de informações puramente autodeclaradas.

O desafio prático não é novo: embora a coleta massiva de dados brutos de mercado já seja uma rotina tecnológica difundida; garantir que cada evento tenha localização confiável e atributos íntegros o suficiente para uma análise fiscal rigorosa é o verdadeiro obstáculo. Os dados brutos extraídos de portais comerciais chegam com dois tipos críticos de ruído:

- Ruído Posicional: CEPs incorretos, números de porta ausentes e coordenadas deslocadas em centenas de metros — imprecisões suficientes para vincular um imóvel ao setor censitário errado.
- Ruído Cadastral: duplicatas do mesmo imóvel em anúncios distintos, valores de área ou preço estatisticamente anômalos, campos obrigatórios ausentes e terminologias fora do padrão da administração pública.

Esta PoC estruturou um pipeline que ataca os dois problemas em paralelo e de forma independente. Para sanar a questão posicional, adotamos o Cadastro Nacional de Endereços para Fins Estatísticos (CNEFE), do IBGE, como nossa referência oficial (ground truth), aliado ao desenvolvimento de um motor de processamento próprio, o Geocoder V3. Esse motor aplica uma lógica de matching em cascata para cruzar, corrigir e qualificar cada registro contra a malha viária oficial. Simultaneamente, o sistema executa um saneamento cadastral robusto para identificar redundâncias e anomalias econômicas.

O resultado é que cada oferta recebe dois flags independentes — integridade cadastral e validação posicional — que podem ser combinados conforme o objetivo da análise. A PoC processou 83.869 ofertas brutas de novembro de 2025 em Florianópolis.

5.2 Fluxo de dados estruturado

5.2.1 Fontes de dados

Para a realização desta Prova de Conceito (PoC) em Florianópolis, o Observatório do Mercado Imobiliário estruturou seu fluxo analítico apoiando-se em duas fontes primárias de dados. Embora distintas em sua natureza e propósito original, essas fontes atuam de forma complementar para alcançar o objetivo central: validar e enriquecer espacialmente a amostra imobiliária, garantindo o rigor exigido pela Receita Federal do Brasil (RFB).

5.2.1.1 1. Dados de Ofertas Imobiliárias (Mercado)

A base que confere o contexto transacional e as características intrínsecas dos imóveis é oriunda de anúncios coletados em portais de mercado, especificamente do **Viva Real**. Esta fonte reflete a dinâmica contemporânea de ofertas (tanto para venda quanto para aluguel) e concentra os atributos cruciais para a modelagem estatística e de precificação.




Figura 5.1: Fluxo completo do pipeline de dados do Observatório

- **Formato e Armazenamento:** Os dados brutos foram previamente extraídos e estão armazenados de forma particionada e otimizada no Datalake do projeto, padronizados no formato estruturado **Parquet**.
- **Volume da PoC:** A amostra isolada para o município de Florianópolis (SC), com data de referência em novembro de 2025, totalizou **83.869 registros brutos**.
- **Atributos Transacionais e Estruturais:** A base compreende uma extensa gama de variáveis estruturais e textuais do imóvel (tais como tipologia, área total e útil, número de quartos, suítes, vagas de garagem, valor do imóvel, IPTU, taxa condominial, além de descrições em texto livre e amenidades).
- **Atributos Locacionais e Geocodificação Primária:** Os anunciantes fornecem dados básicos de localização (CEP, logradouro, número, bairro). Originalmente, este conjunto de dados já contava com uma camada de geolocalização primária processada pela **API do ArcGIS**, que atribuiu coordenadas iniciais (latitude/longitude) e um indicador de confiança interno denominado **precisao**. Para garantir a eficácia metodológica da nossa validação cruzada, o escopo da PoC foi afunilado para os **61.416 registros** (aproximadamente 73,2% do total) que apresentavam o indicador **precisao = 4** — nível máximo de exatidão do ArcGIS, que indica teoricamente a localização exata ao nível do número da porta.

5.2.1.2 2. Dados de Referência Espacial Oficial (Governo)

Para atuar como contraponto metodológico e validador irrefutável da geocodificação primária do mercado (ArcGIS), o projeto integrou o **CNEFE (Cadastro Nacional de Endereços para Fins Estatísticos)**.

- **Origem e Confiabilidade:** Tratando-se da base oficial de endereços do território nacional, o CNEFE é gerido, auditado e periodicamente atualizado pelo **Instituto Brasileiro de Geografia e Estatística (IBGE)**. Por conter coordenadas atestadas por profissionais de cartografia governamental, o cadastro cobre virtualmente a totalidade dos endereços válidos e estruturados no Brasil.




Figura 5.2: Mapa de Ofertas

- **Relevância Estratégica e Fonte da Verdade:** A adoção do CNEFE transcende a mera consulta; ele é o pilar que alinha o Observatório às rigorosas premissas de conformidade exigidas pela RFB. Neste projeto, o CNEFE assume o papel metodológico de “**fonte da verdade**” posicional, balizando qualquer divergência de localização.
- **Atributos-Chave e Precisão Dinâmica:** Cada endereço oficial do CNEFE aporta uma chave de identificação única e inalterável (`cod_unico_endereco`), além de padronizar componentes textuais (logradouro, bairro e o CEP com sua grafia correta). O grande diferencial técnico para o sucesso desta etapa foi a extração do atributo `nv_geo_coord` (nível de precisão geográfica do IBGE). Esta métrica, que varia numa escala de 1 (precisão exata, validada no nível da edificação) a 6 (estimativa espacial ampla, no nível de setor censitário), foi o motor que permitiu ao nosso modelo definir dinamicamente os *thresholds* (limites de tolerância em metros) para aceitar, penalizar ou descartar sumariamente as coordenadas sugeridas pelo mercado.

5.2.2 Ingestão

A etapa de ingestão foi desenhada para conectar eficientemente o acervo do Datalake aos motores de geoprocessamento em banco de dados, assegurando que o grande volume de dados (milhares de coordenadas e endereços textuais) fosse transferido, normalizado e indexado de forma idempotente e performática.

5.2.2.1 1. Extração e Carga Inicial

Os dados brutos do portal imobiliário (Viva Real) foram lidos diretamente do Datalake, onde repousam em formato Parquet. O processo de extração não se limitou a carregar as variáveis locais (CEP, Bairro, Rua, Número, Latitude e Longitude geradas pelo ArcGIS), mas também trouxe consigo os atributos transacionais (área, valor, tipologia) que são o insumo principal para a modelagem estatística futura.

5.2.2.2 2. Setup de Infraestrutura e Banco de Dados

A ingestão foi roteada para um banco de dados relacional robusto — **PostgreSQL (RDS hospedado na AWS)**. Para viabilizar as comparações espaciais e textuais avançadas, a etapa de *setup* inicial do script garantiu a ativação de três extensões fundamentais no PostgreSQL:

- **postgis**: Habilita tipos de dados espaciais (**GEOMETRY**) e funções matemáticas complexas (como **ST_Distance**) para cálculo preciso da divergência em metros entre as coordenadas.
- **pg_trgm**: Permite a quebra de textos em sequências de três caracteres (trigramas), essencial para buscas de similaridade (Fuzzy) em endereços com erros de digitação.
- **unaccent**: Garante a normalização de strings removendo acentos diacríticos (ex: igualando “São João” a “Sao Joao”).

5.2.2.3 3. Otimização de Índices (GIN)

Para que as comparações não resultassem em gargalos de performance (“*full table scans*”), a etapa de ingestão arquitetou a criação concorrente (**CONCURRENTLY**) de índices altamente otimizados. Destaca-se o uso do **GIN Index (Generalized Inverted Index)** sobre as colunas de logradouros do CNEFE, utilizando as operações trigramáticas (**gin_trgm_ops**). Isso permitiu que o banco resolvesse consultas complexas de similaridade textual de maneira imediata.

5.2.2.4 4. Fluxo de Processamento (Alto Nível)

Todo o pipeline de ingestão e preparação culmina no roteamento estruturado para o motor de validação. O fluxo de alto nível se dá na seguinte arquitetura:

1. **Entrada**: Filtro dos 54.007 registros alvo (onde **precisao = 4**).
2. **Setup Idempotente**: Criação/Validação de extensões, índices e da tabela de destino `_projeto_rf.monit_2025_11_poc_floripa_v3`.

3. **Cascata de Processamento:** Os dados recém-ingestados são despachados para os múltiplos níveis de validação (L1 a L6) do Geocoder V3.
4. **Enriquecimento:** Emissão de resultados espaciais paralelos, calculando dinamicamente a diferença em metros e as regras de aceite.

5.2.3 Tratamento

O processo de tratamento dos dados é a espinha dorsal metodológica do Observatório, dividido em duas macro-etapas: a padronização e geocodificação no Datalake (fase preparatória) e o *matching* cruzado em banco de dados (fase de validação).

5.2.3.1 1. Normalização e Geocodificação Primária (PySpark ETL)

Antes de chegar ao banco relacional, os dados brutos oriundos das diversas safras mensais do Viva Real são harmonizados no Datalake utilizando **Apache Spark (PySpark)**.

5.2.3.1.1 De-Para Semântico

Os dados brutos coletados frequentemente apresentam termos em inglês ou formatos não padronizados. Durante a etapa de ETL no PySpark, essas propriedades foram rigorosamente higienizadas, tipadas e padronizadas para o vernáculo da Receita Federal. O mapeamento inclui a tradução de tipos de anúncio e tipologias de imóvel, bem como o enquadramento estrutural das colunas no formato canônico da tabela destino, seguindo estritamente as diretrizes do Dicionário de Dados do projeto.

5.2.3.1.2 Higienização e Geocodificação

- **Higienização de Strings:** Os atributos de endereço passam por funções escalares (UDFs) que removem caracteres especiais, acentos (normalização NFKD) e padronizam a caixa alta, gerando chaves limpas para cruzamento.
- **Cálculo da Precisão Inicial:** O script Spark roda uma lógica hierárquica para determinar o grau de confiança da informação inserida pelo corretor (a coluna `precisao`). Um endereço só recebe `precisao = 4` se contiver Rua, Número, Bairro e Cidade devidamente preenchidos.
- **Geocodificação via ArcGIS:** Para os registros novos que ainda não possuem coordenadas em nossa base histórica (`tb_localizacao`), o pipeline do Spark efetua chamadas assíncronas (com estratégias de *retry* exponencial) à API do ArcGIS para obter a primeira coordenada (`lat` e `lon`). Esta coordenada “crua” do mercado é o que será auditado a seguir.

5.2.3.2 2. Saneamento de Registros (Detecção de Outliers)

Antes de qualquer validação geoespacial, o pipeline executa um **sistema robusto de detecção de outliers** que identifica e classifica dados problemáticos nos anúncios imobiliários.

5.2.3.2.1 Objetivo da Etapa

Garantir que: - Análises estatísticas não sejam distorcidas por dados duplicados ou absurdos - Problemas óbvios (quartos impossíveis, preços extremos) sejam sinalizados - Cada registro seja classificado segundo nível de confiança - Bolsistas possam priorizar manualmente os casos mais críticos

5.2.3.2.2 Códigos de Classificação

Código	Status	Descrição
0	Válido	Registro aprovado para análises
1	Duplicado	Mesmo imóvel anunciado múltiplas vezes
2	Com Outliers	Possui um ou mais problemas detectados

Código	Status	Descrição
3	Inválido	Campos essenciais ausentes/impossíveis

5.2.3.2.3 Tipos de Problemas Detectados

O sistema identifica **10 categorias** de anomalias:

- **duplicado** — Mesmo imóvel em múltiplos anúncios
- **campos_null** — Informações essenciais faltando
- **quartos** — Quantidade impossível ou inconsistente
- **suítes** — Mais suítes que quartos
- **banheiros** — Quantidade impossível
- **vagas** — Garagem inconsistente
- **valor** — Preço extremamente alto ou baixo
- **area** — Tamanho impossível
- **vm2** — Valor/m² fisicamente impossível
- **vm2_estatistico** — Valor/m² muito fora do padrão regional (**Principal Indicador**)

5.2.3.2.4 Resultados na POC Florianópolis

Status	Quantidade	Percentual
Válidos (0)	~65.000	77.5%
Com Outliers (2)	~12.000	14.3%
Duplicados (1)	~5.200	6.2%
Inválidos (3)	~1.669	2.0%

Problema mais comum: **vm2_estatistico** representa **70% dos outliers** detectados, confirmando que valor/m² é o melhor sinalizador de anomalias imobiliárias.

5.2.3.2.5 Implementação Técnica

O sistema foi implementado em **PostgreSQL** com o arquivo:

`relatorio_poc_floripa/script_deteccao_outliers_completo_v2.sql.sql` (750-

Adiciona as seguintes colunas na tabela: - **duplicado** — Marcação de duplicata
- **outlier_tipos** — Array de tipos de problemas - **verificado_outliers**
— Validação manual realizada? - **updated_at**, **updated_by**, **observacoes** —
Rastreamento de correções

5.2.3.3 3. Validação Cruzada Avançada (Geocoder V3 - PostGIS)

Com a base de mercado padronizada e as coordenadas primárias (ArcGIS) estabelecidas, o fluxo migra para a validação contra a base governamental. O **Geocoder V3** implementa uma cascata de seis níveis dentro do PostgreSQL: cada nível processa **exclusivamente os registros que todos os níveis anteriores não resolveram**. O processamento para assim que um match é encontrado — garantindo que o critério mais rigoroso sempre tenha prioridade sobre os mais permissivos.

5.2.3.3.1 Pré-processamento de Entrada

Antes de entrar na cascata, cada registro é normalizado inteiramente em SQL:

- **cep_clean:** Remove o hífen do CEP (88010-200 → 88010200).
- **logr_limpo:** Remove prefixo de tipo de logradouro (Rua, Av., Travessa, Servidão, Estrada etc.) via REGEXP_REPLACE, aplica LOWER e unaccent — igualando grafias como “Av. Beira-Mar Norte” e “Avenida Beira Mar Norte” antes de qualquer comparação.

Esta normalização é o que permite ao L1 (match “exato”) funcionar mesmo com variações menores de grafia entre portais imobiliários e o cadastro oficial.

5.2.3.3.2 Níveis da Cascata

Nível	Nome	Chaves de Match	Score
L1	Exact	CEP + Logradouro normalizado + Número exato	1,00 (fixo)
L2	Fuzzy Number	CEP + Trigrama logradouro (0,40) + Número mais próximo	Composto
L3	Interpolated	CEP + Logradouro exato + Interpolação entre bounds numéricos	Dinâmico
L4	Fuzzy Street	CEP + Trigrama logradouro (0,40), sem número	Trigrama
L5	Fuzzy Bairro	Bairro exato + Trigrama logradouro (0,40) + Número próximo	Composto
L6	No Match	—	0,00

5.2.3.3.3 Descrição de Cada Nível

L1 — Match Exato: Correspondência de `cep_clean` + `logr_limpo` + número exato (TRIM em ambos os lados). Score fixo em 1,00. Respondeu por **22.098 dos 54.007 matches** (40,9%) — os mais confiáveis da base.

L2 — Fuzzy Number (Score Composto): Para registros com número informado mas sem match exato, busca o número oficial mais próximo dentro do mesmo CEP. Opera com dois thresholds de trigramma distintos: um *pré-filtro* (0,35) que usa o índice GIN para eliminar candidatos sem entrar em *full scan*, e um de *aceitação final* (0,40) após o LATERAL JOIN. O candidato é selecionado ordenado pela menor diferença numérica e, em empate, pela melhor precisão IBGE (`nv_geo_coord`). O score pondera:

$$Score = 0,65 \times Simil_{trigramma} + 0,35 \times \frac{1}{1 + |N_{mercado} - N_{cnefe}|}$$

L3 — Interpolação Linear: Quando o número não existe no CNEFE mas o CEP e logradouro existem com outros números, estima a coordenada por interpolação linear entre os dois vizinhos conhecidos (bound inferior e superior). Requer `logr_limpo` exato (sem fuzzy), garantindo que a interpolação ocorra dentro do logradouro correto. A fórmula é:

$$lat_{interp} = lat_{baixo} + \frac{N_{alvo} - N_{baixo}}{N_{alto} - N_{baixo}} \times (lat_{alto} - lat_{baixo})$$

O score parte de 0,90 e decai com o intervalo entre os bounds (0,90 - 0,0001 × gap). Filtro conservador: resultados com distância > 500m são descartados.

L4 — Fuzzy Street: Para registros sem número válido (ou cujo número não auxiliou nos níveis anteriores), busca apenas por similaridade de logradouro dentro do mesmo CEP — sem considerar numeração. Usa os mesmos thresholds de pré-filtro (0,35) e aceitação (0,40). É o nível com maior dispersão de distância (mediana de 252m).

L5 — Fuzzy Bairro (sem CEP): Fallback para registros com CEP ausente ou inválido. Substitui a âncora do CEP pelo bairro exato (`dsc_localidade` = `bairro_tratado`) e aplica a mesma fórmula de score composto do L2.

Processado em batches de 500 registros para evitar locks longos no banco. Usa índice GIN sobre `f_unaccent(nom_seglogr)` para viabilizar o pré-filtro sem CEP.

L6 — No Match: Registros sem aderência em nenhum nível são registrados com `cnefe_match_type = 'no_match'`, `confidence_score = 0,00` e `is_problematic = TRUE`. As coordenadas do ArcGIS são mantidas como fallback, sinalizadas como `arcgis_nao_validado`.

Nota de Evolução Metodológica (V3.3): Diferente das versões anteriores, a hierarquia do Geocoder V3.3 prioriza o matching por proximidade numérica (**L2 - Fuzzy Number**) em detrimento da estimativa matemática (**L3 - Interpolated**). Esta decisão visa mitigar erros em logradouros com numeração irregular ou CEPs únicos extensos — cenários onde a interpolação linear poderia sugerir coordenadas teoricamente corretas, mas geograficamente imprecisas. Ao priorizar o match em números oficiais vizinhos já validados pelo IBGE, o modelo adota um viés conservador que aumenta a confiabilidade do dado final.

5.2.3.4 4. Veredito e Tolerância Dinâmica

Após encontrar o correspondente na base do CNEFE, o algoritmo utiliza o `ST_Distance` do PostGIS para calcular a diferença em metros entre a coordenada do mercado (ArcGIS) e a oficial (CNEFE). A aprovação de qual delas prevalecerá como coordenada final não é engessada, ela depende do `nv_geo_coord` (precisão original mapeada pelo IBGE):

- **Precisão IBGE 1 e 2:** A coordenada do mercado só é tolerada se divergir no máximo **100m** da oficial (além de exigir *score* de confiança $\geq 0,80$).
- **Precisão IBGE 3:** Tolerância de até **200m**.
- **Precisão IBGE 4:** Tolerância de até **500m**.
- **Precisão IBGE 5 e 6:** Apenas o score é avaliado (distância ignorada) — coordenada CNEFE é imprecisa demais para servir de referência métrica confiável.

Quando `is_problematic = FALSE` e `nv_geo_coord {1, 2, 3}`, a coordenada **CNEFE substitui** a do ArcGIS como posição final do imóvel. Nos demais casos, a coordenada ArcGIS é mantida, sinalizadas como `arcgis_validado` (dentro dos limites) ou `arcgis_nao_validado` (fora dos limites).

Na PoC de Florianópolis, esse fluxo em cascata processou cerca de **52.386 registros em apenas ~2.4 minutos**, representando uma melhoria de performance de $17\times$ em relação às arquiteturas anteriores.

5.2.3.4.1 Exemplos Práticos da Cascata

Os dois exemplos abaixo ilustram como a lógica de eliminação progressiva funciona na prática.

Exemplo 1 — Registro resolvido no L3 (trace completo da cascata)

Entrada: Apartamento — “*Rua Tenente Silveira, 234, CEP 88010-300, Centro*”

- **L1:** `logr_limpo = "tenente silveira"` | Número 234 não consta no CNEFE para esse CEP+logradouro → **reprovado**
- **L2:** Candidato mais próximo = número 200 ($\text{diff} = 34$).
 $\text{Score} = 0,65 \times 0,99 + 0,35 \times (1 \div 35) = 0,643 + 0,010 = 0,653$ → abaixo de 0,80 → **reprovado**
- **L3:** Bounds encontrados: 200 ($\text{lat} = -27,5901$, $\text{lon} = -48,5510$) e 300 ($\text{lat} = -27,5912$, $\text{lon} = -48,5523$).
 Interpolação com $t = (234 - 200) \div (300 - 200) = 0,34$ → coordenada estimada. $\text{Score} = 0,90 - 0,0001 \times 100 = 0,880$.
 Distância ao ArcGIS = 31 m (500 m) → **APROVADO**

Resultado: `cnefe_match_type = 'interpolated'`, `confidence_score = 0,880`, `is_problematic = FALSE`, coordenada CNEFE adotada como final.

Exemplo 2 — Registro sem match (L6)

Entrada: Lote — “*Servidão das Flores, 80, CEP 88063-999, Lagoa da Conceição*”

- **L1:** CEP 88063999 não existe no CNEFE → **reprovado**
- **L2:** CEP inválido — sem candidatos no pré-filtro → **reprovado**
- **L3:** Sem bounds possíveis pelo CEP inválido → **reprovado**
- **L4:** CEP inválido — sem candidatos pelo CEP → **reprovado**
- **L5:** Bairro “Lagoa da Conceição” encontrado. Trigramas de "servidao das flores" vs. candidatos CNEFE: similaridade máxima = 0,28 ($< 0,35$ do pré-filtro) → nenhum candidato passa → **reprovado**
- **L6:** Registro marcado como `no_match`, `confidence_score` = 0,00, `is_problematic` = TRUE. Coordenadas ArcGIS mantidas como fallback (`arcgis_nao_validado`).

5.2.3.5 5. Triagem de Precisão e Recuperação Espacial (Vias Curtas)

Após a geocodificação inicial com ArcGIS, todos os registros são classificados em três categorias baseadas na coluna `precisao`:

- Precisão < 3 (Baixa Qualidade):** Registros com informações incompletas de endereço (faltam rua, número ou bairro) são descartados da análise, pois carecem de dados suficientes para validação confiável contra o CNEFE.
- Precisão = 4 (Alta Qualidade):** Registros com todas as informações de endereço devidamente preenchidas (rua, número, bairro, CEP e cidade) prosseguem diretamente para a validação cruzada V3.
- Precisão = 3 (Qualidade Intermediária):** Registros com informações parciais (geralmente faltando o número de porta) recebem tratamento especial através da **metodologia de recuperação espacial com vias curtas**.

5.2.3.5.1 Metodologia de Recuperação Espacial (Short Streets)

Para maximizar a cobertura analítica e recuperar registros de precisão 3 que possuem potencial locacional, implementou-se um procedimento operacional baseado na comparação de distâncias a vias curtas versus vias totais.

Premissa: Uma via curta é um logradouro integralmente contido dentro de um único setor censitário. Quando um imóvel está mais próximo de uma via curta do que de qualquer outra via, infere-se que a ambiguidade territorial é menor, justificando seu reaproveitamento.

Algoritmo resumido: Para cada registro de precisão 3, calcula-se a distância até a via curta mais próxima (máx. 100m) e até a via mais próxima da malha viária completa. Se ambas forem equivalentes (tolerância ~2–3m), o registro recebe `flag_reap3 = True` e é incorporado ao pipeline; caso contrário, é descartado.

Bases de Dados Utilizadas:

- `eixos_osm_curtos.gpkg` — Vias curtas (contidas em 1 setor censitário)
- `eixos_osm_dissolvidos.gpkg` — Malha viária completa

Resultado operacional: Na POC Florianópolis, **10.23% dos registros de precisão 3** foram reaproveitados (1.236 de 12.077), elevando a cobertura analítica de ~73% para ~81%. A variação da taxa de reaproveitamento por bairro e tipologia, bem como a validação da metodologia, são detalhadas na [Seção 3.1](#).

5.2.4 Armazenamento

Os dados consolidados foram inseridos num banco **PostgreSQL (RDS AWS)** utilizando os recursos avançados das extensões **PostGIS** e **pg_trgm**. A tabela de saída (`_projeto_rf.monit_2025_11_poc_floripa_v3`) contém tanto as informações do anúncio original quanto as coordenadas cruzadas e o veredito do modelo.

5.3 Resultados Obtidos (V3)

5.3.1 Estrutura

Foi criada e estabilizada a estrutura completa de avaliação de distâncias e aprovação de qualidades espaciais de imóveis. O processamento abrangeu com sucesso **87.9% dos imóveis elegíveis** (com número informado), gerando tabelas altamente indexadas.

Detalhamento do Funil de Qualidade:

O pipeline foi desenhado para filtrar progressivamente o ruído do mercado, garantindo que apenas dados com alta confiabilidade posicional cheguem à análise final.

Tabela 5.4: Funil de processamento e validação cruzada

Etapa do Funil	Registros	% Retenção	Motivo do Descarte / Observação
Ingestão Bruta (Datalake)	83.869	100%	Amostra total (Novembro/2025)
Filtro de Localização (Prec 3/4)	73.493	87.6%	Endereço sem Rua ou Bairro identificado
Elegíveis para CNEFE (V3)	61.416	73.2%	Registros com Número de Porta (precisao=4)
Match CNEFE Identificado	54.007	64.4%	Sucesso no cruzamento L1-L5
Validados RFB (Final)	25.104	30.0%	Alta Precisão (IBGE 1-3) e Confiança Final

Métricas de Desempenho:

- **Registros processados com match CNEFE:** 54.007 (87.9% dos elegíveis)
- **Registros sem match CNEFE:** 7.409 (12.1% dos elegíveis)
- **Tempo de processamento:** ~2.4 minutos (52.386 registros/min)

5.3.2 Bases Consolidadas (V3)

Como resultado primário, construímos a tabela `monit_2025_11_poc_floripa_v3`, na qual verificamos que a **mediana de distância entre os provedores é de 24.35 metros** e a **distância média é de 215.26 metros**.

5.3.2.1 Decisão sobre Coordenadas Finais

No resultado final, aplicou-se a lógica de decisão V3:

- **CNEFE escolhido como fonte definitiva:** 25.104 registros (46.5%)
 - Critério: `is_problematic = FALSE AND nv_geo_coord IN (1, 2, 3)`
 - Estes registros têm alta precisão IBGE (nível de edificação ou face de quadra)
- **ArcGIS mantido como fallback:** 28.903 registros (53.5%)
 - Razões: CNEFE problemático (`is_problematic = TRUE`) OU precisão IBGE baixa (`nv_geo_coord >= 4`)
 - Inclui casos onde distância > threshold dinâmico

5.3.2.2 Análise de Conformidade (150m)

Dos 52.950 registros com distância calculada:

- **Dentro de 150m (Tolerável):** 25.325 registros (47.83%)
- **Fora de 150m (Problemático):** 27.625 registros (52.17%)

Distribuição Detalhada por Intervalos:

Intervalo	Quantidade	Percentual	Status
0-10m	15.909	30.05%	Excelente
10-50m	18.792	35.49%	Muito Bom
50-100m	5.471	10.33%	Bom
100-150m	2.384	4.50%	Aceitável
150-300m	3.270	6.18%	Problemático
300-500m	2.035	3.84%	Muito Problemático
500-1000m	2.792	5.27%	Crítico
1000m+	2.297	4.34%	Crítico

5.3.2.3 Estatísticas de Distância (registros com match)

Métrica	Valor
Total com distância	52.950
Distância Média	215.26 m
Distância Mediana	24.35 m
Distância Mínima	0.00 m
Distância Máxima	31.357 km

A mediana de 24.35m indica que **metade dos registros tem divergência menor que 24 metros**, demonstrando que o algoritmo conseguiu excelente alinhamento em grande parte dos casos. A média é inflacionada por outliers geograficamente distantes (outliers até 31 km).

5.3.2.4 Performance por Tipo de Imóvel

Tipo	Registros	Processados	Taxa
Apartamento	43.809	38.619	88.1%
Casa	18.969	16.674	87.9%

Tipo	Registros	Processados	Taxa
Lote/Terreno	6.120	3.369	55.0%
Cobertura	4.882	4.296	88.0%
Escritório	3.560	3.131	87.9%
Casa de Condomínio	3.148	2.765	87.8%
Outros	3.228	2.853	88.4%

Achado Crítico: Lotes/Terrenos tiveram taxa de processamento significativamente inferior (55% vs 88% geral), indicando desafio específico neste segmento. As causas raiz e recomendações são detalhadas na [Seção 3.2](#).

5.3.2.5 Distribuição por Nível de Matching CNEFE

Tipo de Match	Registros	Dist. Média	Dist. Mediana	Taxa de OK
exact_cep_street_number	22.098	92.6 m	7.4 m	87.3%
fuzzy_number	29.750	294.7 m	44.6 m	45.1%
fuzzy_bairro	564	300.0 m	64.9 m	32.4%
fuzzy_street	527	783.3 m	252.3 m	18.2%
interpolated	11	190.4 m	162.0 m	54.5%
no_match	1.057	—	—	0%

Interpretação: O L1 (exact) tem qualidade excepcional (87.3% dentro de 150m), mas o L2 (fuzzy_number) apresenta dispersão maior, sugerindo oportunidade de ajuste de thresholds numéricos (± 50 dígitos máximo).

5.3.3 Dicionário de dados (V3)

Toda a modelagem foi devidamente mapeada no Dicionário de Dados oficial (DICIONARIO_DADOS.md v3). Ele detalha minuciosamente a natureza das colunas expandidas, incluindo:

- **Campos de Rastreabilidade Novos:** `origem_coordenada`, `processo_geo`, `lat_final`, `lon_final`, `geom_final`
- **Campos de Decisão:** `is_problematic` (dinâmico por `nv_geo_coord`), `geo_precision_score`, `cnefe_nv_geo_coord`
- **Campos Herdados:** `confidence_score`, `distance_meters`, `cnefe_match_type`, `verificado`

Estabelece a semântica correta para as equipes da RFB, incluindo explicação detalhada da lógica de threshold dinâmico.

5.4 Análises Aprofundadas e Validação

Nesta seção, apresentamos análises detalhadas conduzidas pelos bolsistas do projeto, ilustrando aplicações práticas da metodologia desenvolvida e evidenciando padrões identificados durante a validação cruzada ArcGIS vs CNEFE.

5.4.1 1. Metodologia de Recuperação: Vias Curtas (Short Streets)

Período: Janeiro - Março 2026 **Objetivo:** Demonstrar como registros de precisão intermediária (precisão = 3) podem ser recuperados através de análise espacial comparativa com malha viária de setores censitários únicos.

A descrição do fluxo operacional dessa metodologia no pipeline de tratamento encontra-se na Seção *Triagem de Precisão e Recuperação Espacial*; esta seção detalha os resultados analíticos e a validação da hipótese territorial.

5.4.1.1 Metodologia

O procedimento implementa um filtro espacial de dupla verificação:

1. **Seleção do Universo:** Identificam-se todos os 12.077 registros classificados como precisão 3 (sem número de porta informado)
2. **Cálculo de Proximidade #1:** Para cada registro, calcula-se a distância até a **via curta mais próxima** (máx. 100m)
3. **Cálculo de Proximidade #2:** Para o mesmo registro, calcula-se a distância até a **via mais próxima** de toda a malha viária
4. **Comparação:** Se ambas as distâncias forem equivalentes (tolerância 2-3m), conclui-se que a via curta é a principal referência
5. **Marcação:** O registro recebe `flag_reap3 = True` (reaproveitável) ou `False` (descartável)

Bases Geográficas Utilizadas: - `eixos_osm_curtos.gpkg` — 1.236 vias curtas (integralmente dentro de 1 setor censitário) - `eixos_osm_dissolvidos.gpkg` — Malha viária completa - Sistema de referência: EPSG:31982 (coordenadas métricas)

5.4.1.2 Resultados

Taxa Global de Recuperação: 10.23% dos registros de precisão 3 (1.236 de 12.077) foram reaproveitados.

Distribuição Territorial (TOP 10 Bairros):

Bairro	Precisão 3	Reaproveitados	Taxa
Rio Tavares	196	61	31.12%
São João do Rio Vermelho	361	86	23.82%
Saco dos Limões	63	15	23.81%
Itacorubi	523	109	20.84%
Estreito	197	34	17.26%
Córrego Grande	203	34	16.75%
Agrônoma	406	59	14.53%
Jurerê Internacional	901	121	13.43%
Trindade	389	50	12.85%
Lagoa da Conceição	196	25	12.76%

Distribuição por Tipo de Imóvel:

Tipo	Precisão 3	Reaproveitados	Taxa
Casa	3.137	447	14.25%
Lote/Terreno	1.230	151	12.28%
Escritório	430	44	10.23%
Apartamento	5.443	433	7.96%
Ponto Comercial	283	26	9.19%
Casa de Condomínio	548	49	8.94%
Cobertura	741	55	7.42%

Análise de Características (Reaproveitados vs Não Reaproveitados):

Variável	flag_reap3=True (Mediana)	flag_reap3=False (Mediana)	Diferença
Valor (R\$)	1.308.000	1.260.000	+3.8%
Área (m ²)	151	130	+16.3%
Quartos	3	3	—
Banheiros	2	2	—
Vagas Garagem	2	2	—

Interpretação: Os registros reaproveitados apresentam áreas e valores ligeiramente maiores, sugerindo que a metodologia captura bem imóveis em localidades mais estruturadas (onde vias curtas existem).

A metodologia é **conservadora por design**: apenas 10,23% dos registros de precisão 3 passam no filtro, garantindo que apenas aqueles com evidência territorial forte sejam reaproveitados. A cobertura analítica sobe de ~73% para ~81% sem comprometer a qualidade posicional. A variação territorial observada — Rio Tavares (31%) vs. Ingleses do Rio Vermelho (3%) — indica que a densidade e regularidade da malha viária influenciam diretamente a taxa de recuperação.

5.4.2 2. Análise Exploratória: Desempenho em Lotes e Terrenos

Período: Março 2026 **Objetivo:** Investigar as causas raiz da menor taxa de processamento em imóveis não-edificados e propor estratégias de melhoria específicas para este segmento.

O achado quantitativo deste segmento é destacado em *Performance por Tipo de Imóvel* (Seção de Resultados); esta seção aprofunda a metodologia de diagnóstico, as causas raiz e as recomendações.

5.4.2.1 Metodologia

Para entender o desempenho inferior de Lotes/Terrenos, executou-se análise exploratória através de:

1. **Segmentação:** Isolamento dos 6.120 registros classificados como tipo_imovel = “Lote/Terreno”
2. **Métricas Comparativas:** Cálculo de taxa de processamento, conformidade <150m, distância média/mediana vs média geral
3. **Análise Geográfica:** Identificação de bairros com pior performance neste segmento
4. **Análise de Matching:** Distribuição por tipo de match CNEFE (exact, fuzzy_number, fuzzy_street, etc.)

5.4.2.2 Resultados

Taxa de Processamento Comparativa:

Métrica	Lote/Terreno	Geral	Diferença
Taxa de Processamento	55.0% (3.369 de 6.120)	89.6% (54.007 de 60.230)	-34.6%
Conformidade <150m	33.66% (1.134 de 3.369)	47.83% (25.325 de 52.950)	-14.17%

Métrica	Lote/Terreno	Geral	Diferença
Distância Média	569.92 m	215.26 m	+ 354.66 m
Distância Mediana	52.71 m	24.35 m	+ 28.36 m

Bairros com Pior Performance (Lote/Terreno):

Bairro	Total	OK	% OK	Dist. Média
Ratones	177	18	10.2%	505.2 m
Ingleses do Rio Vermelho	282	60	21.3%	2.028.1 m
São João do Rio Vermelho	146	33	22.6%	717.6 m
Rio Tavares	132	38	28.8%	570.6 m
Itacorubi	128	33	25.8%	151.1 m
Centro	139	38	27.3%	453.9 m

Distribuição por Tipo de Match CNEFE:

Tipo de Match	Total	Dist. Média	Dist. Mediana
fuzzy_number	2.206	524.1 m	86.5 m
exact_cep_street_number	964	640.2 m	17.4 m
fuzzy_street	166	804.6 m	256.2 m
fuzzy_bairro	33	396.6 m	221.3 m
no_match	108	—	—

Causas raiz identificadas:

1. **Ausência de numeração:** 45% dos lotes não têm match CNEFE porque não possuem número de porta definido
2. **Prioridade CNEFE:** a base oficial prioriza edificações; lotes vagos têm cobertura reduzida
3. **Áreas de expansão:** lotes em periferias concentram precisão IBGE baixa (nv_geo_coord = 5–6)

4. **Score L2 degradado:** com diferenças numéricas acima de 100 (ex: lote 100 vs. CNEFE 500), o componente numérico do score cai drasticamente — $\text{score} = 0,65 \times 0,95 + 0,35 \times (1 \div 401) = \mathbf{0,618}$ (abaixo do threshold 0,80)

5.4.3 3. Validação de Acurácia (Benchmarking com Google Maps)

Autor: Ville Rodrigues **Período:** Abril 2026 **Objetivo:** Avaliar a qualidade das coordenadas do CNEFE e do ArcGIS tomando o Google Maps como referência de maior acurácia (Ground Truth).

5.4.3.1 Metodologia

A análise comparou três pares de coordenadas em quatro níveis de geocodificação do IBGE (NV_GEO_COORD): - **ArcGIS × Google:** Avalia o erro do provedor de mercado. - **CNEFE × Google:** Avalia o erro da base oficial. - **CNEFE × ArcGIS:** Avalia a convergência entre as fontes alternativas.

A amostra abrangeu aproximadamente 3.200 anúncios geocodificados manualmente no Google Maps para garantir a integridade da comparação.

5.4.3.2 Resultados Sintéticos

A tabela abaixo resume as medianas de distância (em metros) para os quatro níveis de precisão do CNEFE:

Nível (NV_GEO_CO-ORD)	Descrição IBGE	Mediana ArcGIS × Google (m)	Mediana CNEFE × Google (m)	Mediana CNEFE × ArcGIS (m)
1	Urbana: Edificação	17,10	27,63	23,85
2	Urbana: Face de quadra	21,99	26,04	12,59
3	Urbana: Centro de quadra	20,15	37,80	31,48
4	Urbana: Setor/Ou- tros	25,56	45,20	64,88

5.4.3.3 Principais Conclusões do Estudo

1. **Performance Relativa:** No caso típico (mediana), o **ArcGIS** foi **mais próximo do Google em todos os níveis**, indicando que as coordenadas de mercado são altamente competitivas para uso imediato.
2. **O Trunfo do Nível 2:** O **Nível 2 (Face de Quadra)** apresentou o quadro mais equilibrado, com o CNEFE mostrando leve vantagem acumulada nas faixas de até 50m e 100m, demonstrando ser a faixa de maior confiabilidade da base oficial.
3. **Fragilidade no Nível 4:** O Nível 4 revelou a maior degradação do CNEFE, com mediana de erro de **45,20m** contra o Google, reforçando a necessidade de thresholds mais largos (500m+) para esta categoria no modelo V3.
4. **Confiabilidade do Match Exato:** O tipo de correspondência **exact_cep_street_number (L1)** provou ser o mais robusto no CNEFE, com 88,3% dos casos dentro de 50m do ponto real do Google no Nível 1.
5. **Heterogeneidade Espacial:** O estudo confirmou que a precisão não é uniforme; bairros como o **Centro** apresentam alta aderência em

ambas as fontes, enquanto áreas como **Ponta das Canas** sofrem com deslocamentos significativos no CNEFE.

O estudo conclui que o ArcGIS é, em média, a fonte que mais se aproxima do ponto de referência ideal. Contudo, o CNEFE — especialmente em `nv_geo_coord 1 e 2` — é uma fonte validadora robusta. O uso do CNEFE deve ser sempre **qualificado pelo nível de precisão e tipo de correspondência**, conforme implementado na lógica do Geocoder V3.

5.4.4 4. Recomendações e Próximos Passos

Para consolidar os aprendizados da POC Florianópolis e escalar para Lote 1 e Lote 2, recomenda-se:

1. **Benchmark V2 vs V3:** Comparação quantitativa de todas as métricas entre as duas versões do Geocoder
 2. **Análise de Outliers:** Investigação manual dos 9.625 registros com distância > 500m (erros potenciais)
 3. **Ajuste de Thresholds Lote/Terreno:** Aumentar tolerância numérica de ± 50 para ± 100 dígitos especificamente neste tipo
 4. **Integração de Fontes Secundárias:** OpenStreetMap e Google Maps para preenchimento dos 12% sem match CNEFE
 5. **Modelagem Preditiva:** Treinar ML para prever `is_problematic` antes do processamento (priorizar revisão manual)
-

5.5 Desafios

5.5.1 Qualidade de dados

Os dados fornecidos pelas APIs imobiliárias apresentam alto nível de ruído: CEPs incorretos, números de porta ausentes ou logradouros preenchidos no campo de bairro.

5.5.2 Validação Posicional e Integridade da Oferta são Processos Independentes

A Detecção de Outliers e a Validação Posicional (Geocoder V3) rodam em paralelo sobre a mesma base e produzem flags independentes. Uma oferta pode ter a posição confirmada pelo CNEFE e ainda assim ser uma duplicata, ter número de quartos, área ou valor/m² fora do esperado, ou campos obrigatórios ausentes — e vice-versa. Os dois processos não se invalidam: eles respondem a perguntas diferentes.

Isso tem uma implicação direta sobre os números de cobertura. O Geocoder V3 validou posicionalmente **25.325 ofertas** (`is_problematic = FALSE`). Mas essas 25.325 não são homogêneas:

- **14.921** → posição validada e oferta íntegra
- **6.982** → posição validada, mas são **duplicatas**
- **3.419** → posição validada, mas com **atributos da oferta suspeitos** (área, vagas, valor/m²)
- **3** → posição validada, mas com **campos obrigatórios ausentes**

O número que efetivamente combina os dois critérios — posição validada e oferta íntegra — é **14.921 imóveis**.

5.5.2.1 Problema Crítico: Lotes/Terrenos

Uma dificuldade notável ocorre com Lotes e Terrenos, onde a taxa de processamento foi apenas **55.0%** (3.369 de 6.120 imóveis), 34,6 pontos percentuais abaixo da média geral. As principais causas são a ausência de numeração de porta em lotes vagos, a menor cobertura do CNEFE para imóveis não-edificados e a degradação do score no L2 (fuzzy_number) quando a diferença numérica entre lote e edificação vizinha supera ~100 unidades.

A análise completa — com tabelas comparativas por bairro, distribuição por tipo de match e recomendações de ajuste de threshold — está documentada na [Seção 3.2](#) e no arquivo [ANALISE_LOTE_TERRENO_V3.md](#).

5.5.3 Padronização

Enfrentamos o desafio de comparar strings com grafias distintas (ex: “Av. Brigadeiro”, “Avenida Brig.”, “Brig.”). A adoção do *trigram matching* com PostgreSQL e da extensão `unaccent` resolveu a maioria das ocorrências, porém exigiu um ajuste fino dos thresholds de score.

5.5.4 Integração

Conectar bases massivas sem travar a memória ou demorar dias de processamento exigiu reestruturar o pipeline inicial para uso pesado de índices (GIN em PostgreSQL). Além disso, definir qual coordenada “vence” (ArcGIS ou CNEFE) demandou regras complexas que levassem em conta as variáveis `nv_geo_coord` (precisão do IBGE) versus a `precisao` (do ArcGIS).

5.6 Escalabilidade

5.6.1 Replicabilidade do modelo

A arquitetura baseada no Geocoder V3 demonstrou maturidade para escalabilidade. A execução via batch alcançou processamentos acima de 50.000 registros em pouco mais de 2 minutos. O modelo é idempotente, permitindo reinícios sem duplicação, garantindo total replicação para as demais praças nacionais no decorrer dos Lotes 1 e 2.

5.6.2 Dependências externas

Embora robusto, o modelo depende intrinsecamente do avanço do mapeamento do IBGE (CNEFE). Para perfis críticos onde a base governamental tem menor cobertura — como Lotes Vagos ou condomínios em desenvolvimento inicial — a arquitetura já sugere a possibilidade de integração futura com oráculos secundários (Google Maps Geocoding API ou OpenStreetMap Nominatim).

5.7 Conclusão

A Prova de Conceito realizada em Florianópolis atestou a viabilidade técnica e a escalabilidade da arquitetura proposta para o **Observatório do Mercado Imobiliário**. Ao adotar o CNEFE como *ground truth* e implementar o motor de validação cruzada **Geocoder V3**, o projeto superou a dependência exclusiva de coordenadas comerciais autodeclaradas, estabelecendo um novo padrão de rigor posicional e econômico sobre a base de dados imobiliários.

A metodologia adotada produziu dois eixos independentes de qualidade — posicional (`is_problematic`) e econômico-cadastral (`is_outlier`) —, que podem ser combinados conforme o objetivo de cada análise. Essa independência é uma característica deliberada: permite que o analista da RFB aplique filtros progressivos sem descartar dados que podem ser úteis em contextos distintos.

5.7.1 Resultado Final: Base Duplamente Validada

Aplicando simultaneamente os dois filtros de qualidade — `is_outlier = 0` (dado econômico limpo, sem duplicatas e campos válidos) e `is_problematic = FALSE` (posição confirmada pelo CNEFE) —, o resultado da PoC Florianópolis é:

Dataset Pronto para Análise Fiscal Direta

14.921 imóveis com posição validada e oferta íntegra — **17,8% da base bruta** (83.869 registros).

Tabela 5.16: Lote/Terreno representa apenas **5,0%** das ofertas duplamente validadas — reflexo direto da menor taxa de processamento CNEFE (55% vs. 89,6% geral), discutida na [Seção 3.2](#). A expansão dessa cobertura é uma das prioridades dos próximos passos.

Métrica	Valor
Imóveis validados (duplo filtro)	14.921
Distância mediana ao CNEFE	8,86m
Distância média ao CNEFE	17,73m
Composição principal	Apartamento (7.327) · Casa (4.266) · Cobertura (1.082) · Lote/Terreno (753)
Tipo de negócio	Venda (14.525) · Aluguel (294) · Venda/Aluguel (102)

```
-- Filtro recomendado para análise fiscal direta
SELECT * FROM _projeto_rf.monit_2025_11_poc_floripa_v3
WHERE is_outlier = 0
      AND is_problematic = FALSE;
```

A mediana de **8,86m** de divergência posicional entre a coordenada de mercado (ArcGIS) e a oficial (CNEFE) neste subconjunto é significativamente melhor do que a mediana global de 24,35m — evidenciando que os registros mais limpos economicamente também tendem a ter endereçamento mais preciso.

Embora desafios persistam — especialmente na geocodificação de Lotes Vagos e áreas de expansão urbana —, o arcabouço tecnológico está maduro. O Observatório encontra-se estruturalmente preparado para avançar em sua expansão territorial (Lotes 1 e 2) e para dar início às fases de modelagem preditiva e inteligência fiscal que constituem o seu objetivo final.

6 ETAPA 2: Bases Cartográficas Territoriais

6.1 Introdução

6.2 Fluxo de Estruturação Territorial

6.2.1 Entrada de dados cartográficos

6.2.2 Validação topológica

6.2.3 Padronização

6.3 Atividades desenvolvidas

6.3.1 Organização das bases

6.3.2 Validação geométrica

6.3.3 Integração com cadastro

6.4 Resultados

6.4.1 Base territorial estruturada

6.4.2 Consistência topológica

6.5 Desafios

6.6 Escalabilidade

7 ETAPA 3: Modelagem e Planta de Valores Genéricos (PVG)

7.1 Introdução

Este capítulo apresenta os resultados obtidos na Etapa de Modelagem e Planta de Valores Genéricos (PVG) para a cidade de Florianópolis/SC. Na Seção 7.2 encontra-se o fluxo de modelagem utilizado. Todos os passos constantes do fluxo de modelagem são descritos na sequência. Os resultados podem ser vistos na Seção 7.7. Nas seções 7.8 e 7.9 são descritos os principais desafios encontrados e considerações sobre a escalabilidade da solução adotada para o restante do projeto.

7.2 Fluxo de Modelagem


O fluxo de modelagem pode ser visto na Figura 7.1. Basicamente, o fluxo mostra que parte do conjunto de dados (dados de imóveis edificadas) foi utilizada para prever valores de metro quadrado construído (VUM2), gerando uma variável para a localização que posteriormente foi utilizada na modelagem de valores unitários de lotes, assim como na definição do fator de ajuste de mercado.

Para a estimação de valores de metro quadrado construído, foi necessária a classificação dos imóveis edificadas (casas e apartamentos) segundo seu padrão construtivo. Este procedimento encontra-se detalhado na Seção 7.4.1.

Além disso, os dados foram classificados segundo a sua localização geoespacial, conforme pode ser visto na Seção 7.4.2, visando a identificação de submercados imobiliários¹.

Figura 7.1: Fluxograma da estimação do Valor de Referência.

¹Apesar da classificação geoespacial efetuada, verificou-se que, em Florianópolis/SC, os modelos responderam bem à subdivisão dos mercados em distritos, portanto esta segmentação geoespacial dos mercados foi adotada. Optou-se por manter aqui o estudo da divisão geoespacial do mercado para fins de eventual necessidade em outros municípios.



7.3 Limpeza dos dados

Os dados oriundos do observatório do mercado imobiliário foram limpos com o auxílio de regressão robusta. Na regressão linear ordinária o quadrado dos resíduos, r_i , são minimizados:

$$\hat{\beta}_{OLS} = \min_{\beta} r_i^2 = \arg \min_{\beta} (y - \mathbb{X}\beta)^2 \quad (7.1)$$

Já a regressão robusta pode ser ajustada de diversas maneiras, com a aplicação de uma função, ρ , dos resíduos diferentes da função quadrática, como ilustrado na Equação 7.2. O mais natural seria utilizar o absoluto dos resíduos, em lugar do seu quadrado. Porém, a função absoluto, $abs(t)$, não possui propriedades desejáveis (não é uma função derivável em $t = 0$, o que dificulta o processo de minimização). Por isso é mais comum a utilização de uma função como o *M-Estimador* de Huber (PETER J. HUBER, 1964), da Equação 7.3.

$$\hat{\beta}_{RLS} = \arg \min_{\beta} \rho(y - \mathbb{X}\beta) \quad (7.2)$$

Deve-se notar que a função de Huber equivale aproximadamente a um processo de *Winsorização* os resíduos, ou seja, a partir de um determinado valor de k (em geral igual a 1,5) os resíduos são alterados de forma que para $|r_i| > k$ a função de minimização equivale a tomar o valor absoluto dos resíduos e para resíduos em que $r_i \leq k$ são tomados os resíduos quadráticos.

$$\rho_{Huber}(t) = \begin{cases} \frac{1}{2}t^2 & |t| \leq k \\ k|t| - \frac{1}{2}k^2 & |t| > k \end{cases} \quad (7.3)$$

Diversas outras funções foram propostas para a Equação 7.2, como a função *biweight* de Tukey. No entanto, este método de estimação padece do problema de não ser robusto a *outliers* nas variáveis explicativas, porém apenas a *outliers* presentes na variável dependente (no caso, imóveis de valores muito mais altos ou mais baixos do que os que seria previstos pelos modelos).

Para dar conta dos *outliers* presentes nas variáveis explicativas, ROUSSEEUW (1984) propôs dois estimadores: o estimador **LMS** (*Least Median of Squares*), que minimiza a **mediana** dos resíduos quadráticos, e o estimador LTS (*Least Trimmed Squares*, ou Mínimos Quadrados Aparados), que minimiza o quadrado dos resíduos, porém apenas para os “bons” pontos da amostra:

$$\beta_{LTS} = \arg \min_{\beta} \sum_{i=1}^h (y_i - X\beta)_{i:n}^2 \quad (7.4)$$

Resumidamente, o estimador LTS da Equação 7.4 utiliza aproximadamente apenas h pontos da amostra (em geral, $h \approx 0,5 \cdot n$) para um ajuste mais estável, e calcula os resíduos de cada ponto da amostra em relação à esta reta de regressão robusta. Após o cálculo dos resíduos os pontos são classificados como “bons” (pontos cujos resíduos padronizados são menores que 2,5 em módulo) ou “ruins” (em que $|r_i| > 2,5$). Por questões computacionais, a princípio o estimador LMS foi adotado em detrimento do estimador LTS. No entanto, com o desenvolvimento da capacidade de processamento dos computadores, o método LTS tornou-se mais popular e, por isso, foi o escolhido para a limpeza de dados neste projeto.

7.4 Definição de variáveis

Para os imóveis edificadas, foram utilizadas as seguintes variáveis:

- **dist_litoral**: variável numérica quantitativa que mede a distância do imóvel ao litoral, em metros;
- **renda_pct_krigada**: variável numérica quantitativa que mede a renda per capita do censo 2022 (IBGE), krigada, em Reais;
- **tipo_imovel**: variável qualitativa (dicotômica em grupo) que designa a tipologia do imóvel (Apartamento, Cobertura, Flat, Casa ou Casa de Condomínio);
- **area**: variável numérica quantitativa que mede a área privativa do imóvel, em m^2 ;

- **num_banheiros**: variável numérica quantitativa que representa o número de banheiros do imóvel;
- **num_vagas_garagem**: variável numérica quantitativa que representa o número de vagas de garagem do imóvel;
- **num_suites**: variável numérica quantitativa que representa o número de suítes do imóvel;
- **PC**: variável qualitativa (dicotômica em grupo) que designa o padrão construtivo do imóvel (Baixo, Médio ou Alto);
- **Tipologia**: variável qualitativa (dicotômica) que divide a amostra em Apartamentos (Apartamentos, Coberturas e Flats) ou Casas (Casas e Casas de Condomínio).

Já para os lotes, foram utilizadas:

- **area**: variável numérica quantitativa que mede a área do lote, em m^2 ;
- **Dist**: variável numérica quantitativa que representa a média harmônica das distâncias ao centro da cidade e da distância ao litoral;
- **VUM2**: variável numérica quantitativa que representa o valor unitário do metro quadrado construído na localidade do lote;
- **renda_pct_krigada**: variável numérica quantitativa que mede a renda per capita do censo 2022 (IBGE), krigada, em Reais;
- **ca_max**: variável numérica quantitativa que representa o coeficiente de aproveitamento máximo do lote;
- **dens equip_saud**: variável numérica quantitativa que representa a densidade de equipamentos de saúde no entorno do imóvel;
- **tipo_uso**: variável qualitativa (dicotômica) que designa se o imóvel tem um potencial de uso residencial ou comercial.

7.4.1 Classificação de imóveis construídos (padrão construtivo)

Para a classificação de imóveis construídos, adotou-se como variável principal o **valor unitário** (R\$/ m^2), calculado pela razão entre preço anunciado e área

privativa. Essa escolha foi feita por representar, de forma sintética, o posicionamento econômico do imóvel e refletir diferenças construtivas observáveis no mercado.

A aplicação foi realizada separadamente para os conjuntos de **apartamentos** e **casas**, preservando a heterogeneidade entre tipologias. Em seguida, a variável foi padronizada e submetida a agrupamento não supervisionado (**K-Means**, com $k = 3$), com ordenação dos grupos pela média de valor unitário e rotulagem final em três classes técnicas:

- baixo padrão;
- padrão normal;
- alto padrão.

No contexto deste relatório, o K-Means foi utilizado para organizar observações em grupos com maior semelhança interna e maior distinção externa. O algoritmo opera de forma iterativa, alternando duas etapas: (i) alocação de cada observação ao centróide mais próximo; (ii) recálculo dos centróides como média dos elementos de cada grupo. O processo é repetido até estabilização, minimizando a soma dos quadrados das distâncias intragrupo. Como resultado, obtém-se uma tipologia objetiva de padrão construtivo, sem impor limiares arbitrários de preço.

Classificação de Imóveis Construídos (Padrão Construtivo)




Figura 7.2: Fluxo metodológico da classificação de padrão construtivo.

Os histogramas a seguir apresentam a distribuição do valor unitário (R\$/m²) por classe de padrão construtivo gerada pelo K-Means, separadamente para apartamentos e casas. As distribuições confirmam a separação entre os grupos:

em ambas as tipologias, as curvas dos padrões baixo, normal e alto apresentam picos em faixas distintas de valor, com sobreposição controlada nas fronteiras. Essa separação valida que o algoritmo capturou com consistência a segmentação econômica dos imóveis sem necessidade de limiares definidos manualmente.

Para os **apartamentos** (Figura 7.3), o padrão baixo concentra-se predominantemente na faixa de R\$ 5.000 a R\$ 15.000/m², o padrão normal entre R\$ 10.000 e R\$ 20.000/m², e o padrão alto apresenta distribuição mais dispersa, com valores a partir de R\$ 20.000/m² e cauda longa até R\$ 70.000/m², refletindo a heterogeneidade do segmento de alto padrão em Florianópolis.




Figura 7.3: Distribuição do valor unitário por padrão de imóvel — Apartamentos.

Para as **casas** (Figura 7.4), o padrão baixo concentra-se até R\$ 10.000/m², o padrão normal entre R\$ 8.000 e R\$ 15.000/m², e o padrão alto acima de R\$ 15.000/m². Em comparação com os apartamentos, as casas apresentam faixas de valor unitário mais comprimidas e menor dispersão no padrão alto, o que evidencia diferenças estruturais entre as duas tipologias.




Figura 7.4: Distribuição do valor unitário por padrão de imóvel — Casas.

7.4.2 Classificação espacial

Na classificação espacial, as variáveis utilizadas foram as coordenadas geográficas dos registros (**latitude** e **longitude**) para **cada tipologia de imóvel**: apartamentos, casas e lotes. Utilizando as coordenadas (escala z), foi aplicado agrupamento não supervisionado (**K-Means**) por tipologia.

Foram geradas e comparadas as classificações **class_3_cluster** e **class_5_cluster** em cada conjunto tipológico, com inspeção visual da distribuição espacial e da separação entre grupos. Para uso operacional no fluxo da PVG, foi consolidada a classificação final **class_5_cluster**, por apresentar melhor equilíbrio entre detalhamento territorial e estabilidade do tamanho dos grupos.

No agrupamento espacial, o K-Means separa zonas com comportamento locacional semelhante a partir da proximidade entre coordenadas padronizadas. Embora não substitua uma regionalização administrativa formal, essa estratégia melhora a representação da heterogeneidade espacial em cada tipologia e cria estratos técnicos úteis para os modelos de valor.




Figura 7.5: Fluxo metodológico do agrupamento espacial por tipologia.

7.5 Construção dos modelos

Nesta seção são reportados os modelos ajustados para os imóveis edificados e para os lotes urbanos da cidade de Florianópolis/SC.

7.5.1 Modelo de imóveis edificados

Uma vez realizada a limpeza e classificação dos dados segundo o padrão construtivo, foi ajustado um modelo de regressão linear múltipla sobre os dados de imóveis edificados (casas e apartamentos). De posse deste modelo, foram obtidos fatores de homogeneização a partir dos coeficientes estimados para as diversas variáveis explicativas. Então, com estes fatores assim ajustados, os dados da amostra de imóveis edificados foram homogeneizados, para fins de criação de uma superfície de valores de metro quadrado construído. As estatísticas do modelo de regressão de imóveis edificados podem ser vistas na Tabela 7.1.

Tabela 7.1: Modelo de imóveis edificados. Coeficientes exponenci

Termo	Coef.	Erro-padrão	Estat. t	p-va
Intercepto	12.555,05	0,00	2.311,38	0
log1p(dist_litoral/100)	0,99	0,00	-13,21	0
log(renda_pct_krigada/1212)	1,10	0,00	35,59	0

tipo_imovelCobertura	0,97	0,00	-7,73	0
tipo_imovelFlat	0,98	0,02	-0,90	0
tipo_imovelCasa	0,76	0,00	-65,96	0
tipo_imovelCasa de Condomínio	0,79	0,01	-41,15	0
log(area/100):TipologiaAptos	0,88	0,00	-32,86	0
log(area/100):TipologiaCasas	0,90	0,00	-26,73	0
TipologiaAptos:I(num_banheiros - 2)	1,01	0,00	3,86	0
TipologiaCasas:I(num_banheiros - 2)	1,01	0,00	4,03	0
TipologiaAptos:I(num_vagas_garagem - 2)	1,05	0,00	24,70	0
TipologiaCasas:I(num_vagas_garagem - 2)	1,01	0,00	11,23	0
TipologiaAptos:I(num_suites - 1)	1,05	0,00	26,68	0
TipologiaCasas:I(num_suites - 1)	1,04	0,00	22,50	0
TipologiaAptos:PCAlto	1,55	0,00	143,46	0
TipologiaCasas:PCAlto	1,54	0,00	95,65	0
TipologiaAptos:PCBaixo	0,64	0,00	-146,19	0
TipologiaCasas:PCBaixo	0,62	0,00	-125,52	0

^a Erro-padrão dos resíduos: 0,17 em 32128 graus de liberdade

^b R2: 0,86

^c R2aj: 0,86

^d AIC: -22.881,53

Como é possível notar na Tabela 7.1, foram utilizadas como variáveis explicativas do logarítmo natural dos preços unitários as variáveis citadas na Seção 7.4. É possível notar na Tabela 7.1, ainda, que as variáveis explicativas **area**, **num_banheiros**, **num_vagas_garagem**, **num_suites** e **PC** foram consideradas com efeitos diferentes segundo a **Tipologia**.

Este modelo foi utilizado para a geração de uma superfície de valores (ver Seção 7.7).




Figura 7.6: Clusterização espacial por tipologia com comparação entre class_3_cluster e class_5_cluster (apartamentos, casas e lotes).

7.5.2 Modelo de Lotes

Com a variável VUM2 criada a partir do modelo de lotes edificados, foi ajustado um modelo linear generalizado, com família gamma e função de ligação log. As estatísticas desse modelo podem ser vistas na Tabela 7.2.

Tabela 7.2: Modelo linear generalizado de lotes urbanos. Coeficientes exponenciados.

Termo	Est.	Erro-padrão	Est. t	p-valor	IC_inf	IC_sup
Intercepto	2.449,01	0,05	169,54	0	2.307,02	2.590,99
log(area/450)	0,70	0,01	-49,63	0	0,69	0,71
log1p(Dist)	0,99	0,00	-3,93	0	0,98	1,00
log(VUM2/10000)	2,56	0,05	18,97	0	2,40	2,72
log(renda_pct_krigada/1212)	1,43	0,03	14,25	0	1,38	1,48
I(ca_max - 1)	1,09	0,01	14,88	0	1,08	1,10
log1p(dens_equip_saud)	1,07	0,01	9,25	0	1,06	1,08
tipo_usoResidencial	0,73	0,04	-8,66	0	0,70	0,76

^a Erro-padrão dos resíduos: 0,50 em 3820 graus de liberdade

^b Pseudo-R² (Nagelkerke): 0,62

^c AIC: 62.643,75

No modelo da Tabela 7.2, para a explicação dos valores unitários dos lotes foram utilizadas como variáveis explicativas *area*, *Dist*, *VUM2*, *renda_pct_krigada*, *ca_max*, *dens_equip_saud* e *tipo_uso*, descritas na Seção 7.4.

Os resíduos do modelo da Tabela 7.2 foram krigados, conforme procedimento descrito na Seção 7.6. Por fim, estes resíduos krigados foram utilizados como uma variável explicativa de localização (*layer*) para o ajuste do modelo final de lotes, da Tabela 7.3:

Tabela 7.3: Modelo de lotes urbanos. Coeficientes exponenciados.

Termo	Est.	Erro-padrão	Est. t	p-valor	IC_inf	IC_sup
Intercepto	1.784,45	0,03	256,23	0	1.718,85	1.850,05

log(area/450)	0,68	0,00	-76,61	0	0,68
log(VUM2/10000)	2,96	0,03	32,09	0	2,83
log(renda_pct_krigada/1212)	1,42	0,02	20,44	0	1,39
I(ca_max - 1)	1,08	0,00	20,45	0	1,08
log1p(dens_equip_saud)	1,07	0,01	13,21	0	1,06
tipo_usoResidencial	0,83	0,02	-7,33	0	0,81
layer	2,72	0,02	59,38	0	2,66

^a Erro-padrão dos resíduos: 0,34 em 3796 graus de liberdade

^b R2: 0,82

^c R2aj: 0,82

Como é possível notar na Tabela 7.3, o modelo final tem poder de explicar em torno de 82% dos preços unitários de mercado, um resultado que pode ser considerado notável, se consideramos a falta de diversas variáveis acerca das características físicas dos lotes (frente, forma, pedologia e outras).

Este modelo, portanto, pode ser considerado viável para a predição de valores unitários de terrenos visando a aplicação do método evolutivo para toda a cidade.

7.6 Atividades Desenvolvidas

7.6.1 Seleção de variáveis

A seleção das variáveis envolvidas nas análises não foi feita de forma automática, mas através da inclusão e exclusão manual de variáveis, testando com cada combinação os modelos, até que um modelo ótimo fosse obtido, apenas com aquelas variáveis consideradas importantes, evitando assim o fenômeno do *overfitting*.

Os algoritmos de seleção de variáveis

7.6.2 Testes de modelos

O modelo utilizado para a confecção da superfície de valores de metro quadrado construído é um modelo preditivo que, por este motivo, não demanda uma verificação pormenorizada das hipóteses da inferência clássica.

Para o modelo de lotes, contudo, seria desejável que as hipóteses da inferência clássica (linearidade, normalidade e homoscedasticidade) fossem todas verificadas. No entanto, nem sempre é fácil conseguir um modelo com estas características. A não-verificação das hipóteses da inferência clássica, contudo, não invalidam a propriedade de consistência do estimador de mínimos quadrados (MATLOFF, 2017, p. 81). Ou seja, quando o tamanho da amostra n tende a infinito, o valor estimado, $\hat{\beta}$, tende a β , independentemente de verificação das hipóteses de homoscedasticidade e normalidade.




Figura 7.7: Mapa de Valores de metro quadrado construído (R\$/m²).

7.7 Resultados

7.7.1 Superfície de valores de metro quadrado construído

7.7.2 Modelo preliminar

7.7.3 *Outputs* de valor

7.8 Desafios

7.8.1 Qualidade das variáveis

7.8.2 Aderência ao mercado

7.9 Escalabilidade

7.9.1 Replicação em outros municípios

Parte II

Blocos Transversais

8 Estudos Metodológicos

8.1 Fundamentos da Avaliação em Massa

Segundo CARRANZA et al. (2026), existem diversas abordagens viáveis para a avaliação em massa de imóveis urbanos. CARRANZA et al. (2026) elencam três dessas diferentes abordagens - estimação via algoritmos de *Machine Learning*, Geoestatística (krigagem) e modelos lineares - e as compara no contexto da América Latina.

Cada uma destas diferentes abordagens possui pontos fortes e fracos. De um lado, segundo CARRANZA et al. (2026), a estimação via modelos lineares tem a vantagem de explicar claramente aos contribuintes como são compostos os valores de mercado estimados, ainda que a performance destes modelos geralmente seja mais baixa na previsão destes valores. De outro lado, os algoritmos de *Machine Learning* apresentam performance superior, porém falham em explicar ao contribuinte como são formados os valores de mercado. Entre estas duas abordagens citadas situa-se a geoestatística que, segundo CARRANZA et al. (2026), atinge uma performance aceitável, ainda que apresente problemas em identificar barreiras urbanas.

Neste trabalho procurou-se combinar as diferentes abordagens para uma melhor estimação dos valores de mercado. Como será visto ao longo deste capítulo, os algoritmos de *Machine Learning*, a geoestatística e os modelos lineares foram combinados de maneira que possibilitou a estimação de valores de mercado de maneira suficientemente precisa, sem abrir mão do poder de explicação da formação de valores.

8.1.1 Metodologia

O método adotado para a estimação de valores de mercado neste trabalho é o método evolutivo, método consagrado que estima o valor de mercado de um imóvel através da soma dos seus componentes (terra e capital):

$$V_{\text{Imóvel}} = (V_{\text{Terreno}} + V_{\text{Benfeitorias}}) \cdot FC \quad (8.1)$$

Em que:

- $V_{\text{Imóvel}}$ é o valor de mercado do imóvel acabado;
- V_{Terreno} é o valor de mercado do lote sobre o qual o imóvel encontra-se edificado;
- $V_{\text{Benfeitorias}}$ é o valor do capital aplicado em benfeitorias no imóvel e;
- FC é um “fator de comercialização” empregado para ajustar a diferença entre o valor real de mercado do imóvel e a diferença entre a soma dos seus componentes.

Como descrito nos Capítulos 5 e 6, para a estimação foram coletados dados de anúncios de imóveis edificados e não-edificados, que foram fortalecidos com variáveis cartográficas para adicionar poder de explicação aos valores de mercado. Procurou-se, durante o processo de estimação, extrair o máximo de informação de todo o conjunto de dados, que envolvem anúncios não apenas de lotes, mas também de casas, apartamentos e outros tipos de imóveis, tanto para a venda quanto para locação.

Os valores de benfeitorias podem ser calculados através dos custos de construção divulgados pelos SINDUSCON locais. Os valores dos terrenos, por outro lado, devem ser estimados via modelos lineares, geoestatística ou algoritmos preditivos de aprendizado de máquina. Para o fator de comercialização, o ideal é que este seja inferido através de dados de mercado de imóveis edificados.

8.1.2 Resultados

8.1.2.1 Análise Exploratória

A análise exploratória de dados foi feita com auxílio do R, versão 4.5.2.

```
Reading layer `variavel_geografica_setor_censitario' from data source
`/Users/droubi/Documents/LabFSG/POC-FLN/data/4205407_Florianopolis_r00
03-23.gpkg'
  using driver `GPKG'
Simple feature collection with 1004 features and 54 fields
Geometry type: MULTIPOLYGON
Dimension:      XY
Bounding box:   xmin: -48.61347 ymin: -27.85377 xmax: -48.32788 ymax: -
27.26797
Geodetic CRS:   SIRGAS 2000
```

Na Figura 8.1 é possível perceber a presença de forte assimetria nos dados oriundos do observatório do mercado imobiliário (variáveis P_{Ue} area), causada pela presença de *outliers* na amostra.

8.1.2.2 Limpeza dos dados

Os dados foram limpos utilizando-se regressão robusta. O método de regressão robusta escolhido foi o método dos mínimos quadrados ponderados (ver ROUSSEUW, 1984).

8.1.2.3 Geração da Renda Krigada

Os dados de renda do chefe do domicílio do IBGE foram tratados pela equipe de estimação. Inicialmente foi gerada a variável renda per capita, obtida conforme a Equação 8.2:




Figura 8.1: Análise Exploratória para os dados de Lotes

$$R_{\text{per capita}} = \frac{R_{\text{chefe dom.}}}{N} \quad (8.2)$$

Em que:

- $R_{\text{chefe dom.}}$ é a renda do chefe do domicílio divulgada pelo censo 2022 (IBGE);
- N é o número de pessoas por domicílio, também divulgada pelo IBGE.

Na Figura 8.2 pode ser visualizado o resultado da krigagem da variável $R_{\text{per capita}}$ para o município de Florianópolis.




Figura 8.2: Renda per capita krigada para o município de Florianópolis.

8.1.2.4 Ajuste do modelo de imóveis edificadas

Após a limpeza dos dados, foi executado o processo de classificação dos dados segundo o padrão construtivo. Os dados foram agrupados em três padrões

construtivos, a saber, padrão baixo, normal e alto, conforme descrito na Seção 7.4.1.

Então, foi ajustado um modelo de regressão linear múltipla para descrever o comportamento do mercado imobiliário de casas e apartamentos em Florianópolis ver 7.5.1.

8.1.2.5 Geração da superfície de VU de m2 construído

Após o ajuste do modelo de mínimos quadrados ordinários, os dados da amostra utilizados para o ajuste do modelo foram homogeneizados de acordo com fatores de homogeneização estimados diretamente do modelo. Por exemplo, para a variável área, foi derivado o fator área, conforme a Equação 8.3:

$$F_{\text{Área}} = \left(\frac{A_{\text{imóvel}}}{100} \right)^{-0,25} \quad (8.3)$$

Veja Note 2 para entender como é feita a derivação racional de fatores de homogeneização.

Após o procedimento de homogeneização, foi gerada uma superfície de valores de metro quadrado construído com os dados homogeneizados através do algoritmo IDW (*inverse distance weighting*).

i Nota 1: Inverse Distance Weighting

Segundo DRUCK et al. (2004, p. 83), “uma alternativa simples para gerar uma superfície bidimensional” consiste em ajustar uma função bidimensional sobre as amostras, prevendo valores em uma grade ($\hat{z}_i$), com a seguinte formulação:

$$\hat{z}_i = \frac{\sum_{j=1}^n w_{ij} z_j}{\sum_{j=1}^n w_{ij}} \quad (8.4)$$

Em que:

- z_j é o valor da cota (VU) de uma amostra vizinha do ponto i da

- grade;
- w_{ij} é um fator de ponderação.

Com base neste esquema básico supra-mencionado, é possível gerar vários interpoladores (vizinho mais próximo, média simples ou média ponderada). A ponderação mais usada consiste em adotar pesos que variam com o inverso de uma potência k da distância euclidiana do ponto da amostra ao ponto da grade em que se deseja prever valores (d_{ij}), assim:

$$w_{ij} = \frac{1}{d_{ij}^k} \quad (8.5)$$

Em que: - $d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$

i Nota 2: Derivação Racional de Fatores

A derivação racional de fatores de homogeneização é feita de acordo com os coeficientes estimados em um modelo de regressão linear múltipla (RLM). Os fatores serão aditivos quando o modelo RLM for ajustado na escala de preços unitários (PU), ou serão multiplicativos quando o modelo RLM for ajustado com a transformação da variável dependente para a escala logarítmica, o que é usual na Engenharia de Avaliações.

Para entender, basta perceber que, para um modelo ajustado na escala logarítmica, tem-se:

$$\log(\widehat{PU}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (8.6)$$

Efetuada a exponenciação em ambos os lados de Equação 8.6, tem-se:

$$\widehat{PU} = \exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k) \quad (8.7)$$

Como a exponencial da soma é o produto das exponenciais, a Equação 8.7 torna-se:

$$\widehat{PU} = \exp(\hat{\beta}_0) \cdot \exp(\hat{\beta}_1 x_1) \cdot \dots \cdot \exp(\hat{\beta}_k x_k) \quad (8.8)$$

Donde entende-se o motivo dos fatores derivados com este modelo serem multiplicativos, pois, deste modelo, deduz-se:

$$F_1 = \exp(\hat{\beta}_1 x_1); F_2 = \exp(\hat{\beta}_2 x_2); \dots; F_k = \exp(\hat{\beta}_k x_k)$$

8.1.2.6 Ajuste do modelo de lotes

Com a superfície de valores de metro quadrado construído elaborada conforme descrito na Seção [8.1.2.5](#).

8.1.2.7 Geração da superfície de valores de lotes

8.2 Definição de variáveis

8.3 Estratégias de modelagem

8.4 Conexão com Normas Técnicas

8.5 Aprendizados aplicados na PoC

9 Fluxo Integrado do Processo

9.1 Descrição do *Pipeline* Completo

9.2 Integração entre Etapas

9.3 Pontos de Controle e Validação

9.4 Interface com a RFB

9.5 Potencial de Automação

10 Visitas Técnicas e Intercâmbio de Conhecimento

10.1 Fortaleza

10.1.1 Objetivo da Missão

10.1.2 Instituições visitadas

10.1.3 Atividades realizadas

10.1.4 Principais aprendizados

10.1.5 Contribuições para o Projeto

10.2 Córdoba

10.2.1 Objetivo da Missão

10.2.2 Instituições e Interlocutores

10.2.3 Experiências observadas

10.2.4 Lições aprendidas

10.2.5 Aplicabilidade no Contexto Brasileiro

11 Infraestrutura Tecnológica (LABFSG)

11.1 Arquitetura de Infraestrutura

A infraestrutura tecnológica do LABFSG encontra-se organizada em torno de três servidores com funções primárias definidas e complementares. Em termos gerais, o `sv-labfsg` concentra a persistência de dados e os serviços centrais do ambiente, o `sv-thinkcentre` sustenta o processamento técnico cotidiano do projeto e o `sv-acesso` estrutura a camada de entrada e publicação interna dos serviços.

- `sv-labfsg`: workstation HP Z420, processador Intel Xeon E5-1620, 15 GiB de memória RAM, SSD local para sistema e RAID1 dedicado aos dados, Ubuntu 22.04.5 LTS e kernel 5.15.0-174-generic. Suas funções primárias são manter o PostgreSQL/PostGIS do projeto, a pilha do OpenProject em Docker e a persistência operacional mais sensível do ambiente.
- `sv-thinkcentre`: Lenovo ThinkCentre M75s Gen 2, processador AMD Ryzen 7 5700G, 30 GiB de memória RAM, armazenamento local em NVMe para sistema e área rápida, além de SSD SATA para dados, Ubuntu 24.04.4 LTS e kernel 6.8.0-107-generic. Suas funções primárias são hospedar a `rstudio-vm`, executar rotinas de processamento em Python e R e operar como estação técnica de apoio conectada ao banco de dados do projeto.
- `sv-acesso`: equipamento com processador AMD Athlon 3000G, 5.7 GiB de memória RAM, armazenamento em LVM local, Ubuntu 24.04.4 LTS e kernel 6.8.0-110-generic. Suas funções primárias são prover DNS

interno, **proxy** HTTP e a camada de acesso administrativo e institucional aos serviços publicados.

Essa distribuição reduz o acoplamento entre acesso, processamento e persistência. Além disso, favorece a governança operacional ao manter, em componentes distintos porém integrados, o ambiente de dados, o ambiente de trabalho analítico e a camada de publicação interna.

11.2 Servidores Disponíveis

11.2.1 produção

O ambiente de produção está concentrado no **sv-labfsg**. Nesse servidor permanecem o cluster PostgreSQL 16/main com PostGIS, a pilha do OpenProject em Docker e a persistência dos dados operacionais centrais do projeto. Por concentrar serviços de produção e dados persistentes, o **sv-labfsg** constitui o componente mais sensível da infraestrutura sob a perspectiva da continuidade operacional.

Por essa razão, a documentação operacional adota maior rigor de governança para qualquer intervenção nesse servidor, exigindo planejamento prévio, estratégia de reversão e validação de backup antes da execução de mudanças relevantes.

11.2.2 backup

O plano de backup hoje está ancorado no **sv-labfsg**, com cópia externa para o Synology/NAS do laboratório. Há dois fluxos principais em operação. O primeiro é o backup diário do OpenProject, executado por **systemd** via **op-backup.timer**, gerando dump lógico do banco, empacotamento dos assets e manifesto com hash. O segundo é o backup geral do servidor, acionado por **/etc/cron.d/backup-servidor**, que encadeia scripts para backup do

PostgreSQL, coleta de artefatos extras, montagem de pacote operacional e envio ao armazenamento externo.

Esse arranjo indica que o LABFSG não depende de uma única cópia de segurança, mas de uma estratégia combinada de backup por serviço e por servidor. Além do fluxo automatizado documentado, também já houve movimentação manual de backups de segurança para o Synology, reforçando a camada externa de preservação dos dados.

11.2.3 dedicado ao projeto

Todos os servidores estão atualmente dedicados ao projeto, cada qual com atribuições específicas. O `sv-labfsg` está orientado à persistência, aos serviços centrais e à sustentação do banco de dados e do OpenProject. O `sv-thinkcentre` está voltado ao processamento técnico ativo, com execução de rotinas em Python e R, suporte ao ambiente de trabalho da `rstudio-vm` e comunicação operacional com o banco de dados do projeto. O `sv-acesso`, por sua vez, está direcionado à organização da camada de acesso, à resolução interna de serviços e à publicação institucional do ambiente.

Esse arranjo distribui responsabilidades sem comprometer a integração entre os componentes. Em vez de concentrar todas as cargas em um único servidor, o projeto opera com servidores especializados que cooperam entre si, o que contribui para melhor desempenho, maior previsibilidade operacional e maior clareza de governança.

11.3 Organização de Dados

11.3.1 Estrutura de diretórios

A organização de dados segue a especialização de cada servidor. No `sv-labfsg`, o diretório mais importante é `/srv/data`, onde ficam tanto o PGDATA do PostgreSQL em `/srv/data/postgres/16/main` quanto os dados persistentes do OpenProject, como assets, logs e backups. Essa separação por subdiretórios

favorece a administração do armazenamento em RAID1 e torna mais claro o que pertence a dados transacionais, dados de aplicação e artefatos de backup.

No **sv-thinkcentre**, a documentação consolidada aponta **/srv/dados** como o principal ponto de armazenamento local, além de **/srv/fast** para uso complementar. Já na **rstudio-vm**, foi formalizado um diretório compartilhado de colaboração em **/srv/rstudio-shared**, acessado pelos usuários por meio do link **~/compartilhado** em suas **home**. Essa organização distingue, de forma clara, os diretórios pessoais de uso individual de uma área comum voltada à troca de arquivos de trabalho entre participantes autorizados.

Também existe uma camada importante de diretórios voltados à operação e à documentação. O checkout operacional do repositório aparece documentado em **/opt/operacao/capacitacao-operacao** e em **/home/admin1/Capacitacao**, servindo como fonte de verdade para scripts, runbooks, wiki técnica e registro de mudanças. Além disso, a organização de dados do projeto considera a estrutura compartilhada no Synology em **smb://serverreceita.synology.me/VRCIB_DS_000123/RECEITA_FEDERAL/**, utilizada como referência externa de armazenamento e organização de acervo.

11.3.2 Versionamento

O versionamento da infraestrutura é tratado como parte da própria operação. O repositório **Capacitacao** centraliza a documentação navegável em **docs/wiki/**, os materiais específicos por domínio técnico e, principalmente, o histórico formal de mudanças em **changes/**. A diretriz operacional registrada no próprio repositório é que mudanças relevantes em produção não devem ocorrer sem um diretório formal de mudança, contendo pedido, plano, impacto, rollback e evidências.

Essa estratégia amplia a rastreabilidade do ambiente, pois não versiona apenas código: versiona também decisões operacionais, comandos executados, critérios de sucesso e registros de validação. O padrão Git adotado reforça essa prática ao recomendar que cada commit represente uma intenção operacional claramente delimitada, sempre evitando o versionamento de segredos e privilegiando a explicitação de rollback.

11.4 Banco de Dados

O ambiente de banco de dados do projeto está concentrado no **sv-labfsg**, em um cluster PostgreSQL 16/main separado da stack do OpenProject. Essa separação é fundamental: o banco **openproject** opera em um contêiner próprio (**openproject-db**), enquanto o PostgreSQL/PostGIS do LabGIS atende ao domínio analítico e geoespacial do projeto. Trata-se, portanto, de dois contextos distintos de governança, backup e operação, ainda que coexistam no mesmo servidor.

A exposição do PostgreSQL/PostGIS foi mantida restrita ao loopback (127.0.0.1:5432), o que evita a publicação direta do serviço na rede e condiciona o acesso remoto ao uso de túnel SSH. Esse arranjo favorece a segurança, a rastreabilidade individual e a redução da superfície de ataque, ao mesmo tempo em que preserva acesso técnico controlado para usuários autorizados.

11.4.1 Estrutura PostGIS

O modelo documentado para o ambiente PostGIS baseia-se em camadas de maturidade dos dados e em organização territorial. As bases principais identificadas no host são **labgis**, **bronze**, **prata** e **ouro**. Em especial, **bronze**, **prata** e **ouro** representam etapas sucessivas do fluxo de dados, permitindo distinguir a ingestão inicial, o tratamento intermediário e a consolidação analítica.

Dentro dessas bases, a estrutura recomendada adota **schemas** territoriais, incluindo **br** e um schema por unidade da federação. Em vez de multiplicar schemas por tema, o repositório propõe manter os temas por convenção de nomenclatura das tabelas, com prefixos como **cartografia_**, **omi_** e **estimacao_**. Essa escolha simplifica a estrutura lógica do banco e mantém a dimensão espacial e territorial como eixo principal da organização dos dados.

11.4.2 Modelagem

Do ponto de vista da modelagem, o ambiente combina duas lógicas complementares. A primeira é a modelagem por camadas (**bronze, prata, ouro**), que organiza o ciclo de transformação dos dados. A segunda é a modelagem territorial por **schema**, que distribui os dados por unidade da federação e por abrangência nacional (**br**). Sobre essa base, os temas do projeto aparecem como convenções de nomes de tabelas e como perfis de acesso, e não como bancos ou **schemas** isolados.

Esse modelo é adequado a um ambiente colaborativo porque permite que diferentes frentes, como cartografia, OMI e estimativa, atuem sobre o mesmo recorte territorial sem gerar proliferação excessiva de estruturas. Em contrapartida, exige disciplina de nomenclatura e governança de permissões por tabela, de modo que a colaboração não comprometa a separação de responsabilidades entre equipes e etapas de processamento.

11.5 Segurança e Governança dos Dados

11.5.1 controle de acesso

O controle de acesso segue o princípio da individualização de credenciais e da minimização da exposição dos serviços. No PostgreSQL/PostGIS, o acesso remoto ocorre por túnel SSH para 127.0.0.1:5432, com cada pessoa utilizando login individual no sistema e **role** correspondente no banco. A documentação do **Capacitacao** explicita que o ideal é preservar esse vínculo entre identidade individual, autenticação no sistema e autenticação no banco, favorecendo revogação pontual e responsabilização por usuário.

No ambiente de RStudio, a autenticação atual é realizada por contas locais do sistema operacional na **rstudio-vm**. A gestão recente de usuários formalizou um grupo compartilhado (**rstudio-shared**), um diretório comum em **/srv/rstudio-shared**, links simbólicos nas **home** dos usuários e permissões

adequadas para leitura e escrita colaborativa. Esse desenho diferencia diretórios pessoais de espaço compartilhado e evita a concessão ampla de privilégios administrativos aos usuários comuns da plataforma.

11.5.2 rastreabilidade

A rastreabilidade é sustentada em três frentes. A primeira é a identidade individual no acesso aos servidores, ao banco e ao RStudio, o que permite associar ações a pessoas específicas. A segunda é o versionamento operacional no repositório **Capacitacao**, onde mudanças, runbooks, scripts e evidências são registrados em Git. A terceira é a própria instrumentação do ambiente, que mantém **timers**, logs de serviços e registros de execução para componentes críticos, como os backups do OpenProject e a publicação periódica de informações de operação do **sv-thinkcentre**.

Esse conjunto torna a operação menos dependente de conhecimento tácito. Em vez de mudanças informais, o ambiente passa a dispor de memória técnica institucionalizada, apoiada por documentação viva e por histórico versionado de intervenções.

11.5.3 auditoria

Do ponto de vista de auditoria, o ambiente já dispõe de mecanismos relevantes, embora ainda em processo de amadurecimento. Os backups do OpenProject geram manifestos com hash, o repositório exige registro de impacto, rollback e evidências em mudanças operacionais, e a documentação de segurança aponta a necessidade de revisão recorrente de logs de SSH, UFW e **systemd**. Além disso, a separação entre o banco do OpenProject e o PostgreSQL/PostGIS do projeto favorece auditorias mais precisas por domínio técnico.

Ao mesmo tempo, a própria wiki registra pontos pendentes que merecem fortalecimento, como endurecimento adicional do **sv-acesso**, revalidação periódica das regras efetivas de firewall e consolidação dos testes de restore. Assim, a auditoria no LABFSG já está incorporada ao desenho de governança, mas ainda se encontra em processo contínuo de amadurecimento e padronização.

12 Plataforma de Apresentação de Resultados

12.1 Objetivo da Plataforma

12.2 Funcionalidades

12.3 Dashboards desenvolvidos

12.4 Interface de Usuário

12.5 Potencial de uso pela RFB

12.6 Integração com Sistemas (ex.: SINTER)

13 Entregáveis do período

13.1 Lista consolidada de entregáveis

13.2 Classificação por Etapa

13.3 Status dos Entregáveis

13.4 Evidências de entrega

13.5 Aderência aos critérios de qualidade

Parte III

Governança

14 Governança e Acompanhamento

14.1 Estrutura de Governança do Projeto

14.2 Reuniões realizadas

14.2.1 Comitê Técnico

14.2.2 Comitê Gestor

14.2.3 Reuniões operacionais

14.3 Processos de validação

14.4 Controle de Qualidade

14.5 Registro e rastreabilidade

15 Indicadores de Desempenho

15.1 Indicadores de Avanço Físico

15.2 Aderência ao cronograma

15.3 Qualidade dos dados

15.4 Qualidade dos modelos

15.5 Indicadores de governança

16 Próximos Passos

16.1 Continuidade da PoC

16.2 Ajustes metodológicos

16.3 Evolução da infraestrutura

16.4 Estratégia de escalonamento

16.5 Integração com Ambiente RFB

Referências

- CARRANZA, J. P.; BOLOGNA, E. L.; LUCCA, C. M. The missing link: Comparing mass appraisal techniques and their implications for urban land valuation policies in Latin America. **Land Use Policy**, v. 166, p. 107998, 2026. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0264837726000827>>.
- DRUCK, S.; CARVALHO, M. S.; CÂMARA, G.; MONTEIRO, A. MI. V. (ORGS.). **Análise Espacial de Dados Geográficos**. Planaltina, DF: Embrapa Cerrados, 2004.
- MATLOFF, N. **Statistical Regression and Classification: From Linear Models to Machine Learning**. Boca Raton, FL, 2017.
- PETER J. HUBER. Robust Estimation of a Location Parameter. **The Annals of Mathematical Statistics**, v. 35, n. 1, p. 73–101, 1964. Disponível em: <<https://doi.org/10.1214/aoms/1177703732>>.
- ROUSSEEUW, P. J. Least Median of Squares Regression. **Journal of the American Statistical Association**, v. 79, n. 388, p. 871–880, 1984. [American Statistical Association, Taylor & Francis, Ltd.]. Disponível em: <<http://www.jstor.org/stable/2288718>>. Acesso em: 5/3/2026.

A Diagramas de Fluxo

B Arquitetura Tecnológica

C Relatórios Técnicos Detalhados

D Scripts e documentações

E Evidências de entregas